MODELAGEM E SIMULAÇÃO DE UMA FILA M/M/1: ANÁLISE DE DESEMPENHO EM DIFERENTES CENÁRIOS

Jeann Victor Batista
Thallysson Luis Teixeira Carvalho
Universidade Federal de Alfenas – UNIFAL-MG
Bacharelado em Ciência da Computação – Análise de Desempenho
Professor: Flávio Barbieri Gonzaga

Resumo

Este trabalho analisa um simulador a eventos discretos de uma fila M/M/1 escrito em C e relaciona seu funcionamento à notação de Kendall, à condição de estabilidade e à Lei de Little. Foram simulados oito cenários, com intensidade de tráfego entre 0,25 e 1,10, cinco horizontes (de 10^2 a 10^6) e 30 repetições por configuração, o que dá 1.200 execuções da versão original e 1.200 de uma versão corrigida. Os valores teóricos foram calculados antes das simulações e comparados às médias por meio de intervalos de confiança; também foram verificados a conservação do fluxo e as diferenças pareadas entre as versões. Com $T = 10^6$ nos cenários estáveis, os erros relativos de E[N] e E[W] ficaram abaixo de 0,3% até $\rho = 0{,}90$ e entre 1,1% e 1,7% para $\rho = 0{,}95$ e $\rho = 0{,}99$. Neste último, horizontes de até 10^4 subestimaram fortemente a teoria. A versão corrigida passou a estimar também E[N_q], E[W_q] e o comprimento máximo da fila, e aceita um período de aquecimento opcional: com $\rho = 0{,}99$ e janela de 10^4, descartar os primeiros 10^5 segundos elevou a estimativa de E[N] de 50% para 97% do valor teórico. Nos cenários crítico e sobrecarregado, a população final cresceu e a vazão ficou próxima da capacidade do servidor. A versão original ultrapassa o horizonte solicitado, mas isso só pesa nas execuções curtas. Medindo o tempo de cada cliente, a Lei de Little foi confirmada de forma independente, e os percentis do tempo de permanência seguiram a exponencial prevista.

Palavras-chave: teoria de filas; simulação a eventos discretos; M/M/1; Lei de Little; análise de desempenho.

1 Introdução

Em servidores, roteadores, processadores e discos, uma solicitação às vezes chega com o recurso ocupado e precisa esperar. O que se quer saber é como a carga muda a utilização do recurso, o número de solicitações presentes e o tempo até cada uma ser concluída.

A teoria de filas dá fórmulas fechadas para essas medidas, mas só quando certas hipóteses valem. A simulação a eventos discretos reproduz o sistema no computador e permite observá-lo mesmo fora dessas hipóteses. O caso clássico é a fila M/M/1, com chegadas e atendimentos exponenciais e um único servidor (TRIVEDI, 2001). Colocar as duas abordagens lado a lado tem um benefício extra: a divergência entre elas costuma apontar erros de implementação (ROSS, 2006).

Este trabalho parte do arquivo `simulacao_v3.c`, fornecido na disciplina. O programa gera chegadas e saídas, controla quantas solicitações estão no sistema e calcula a ocupação, o número médio de solicitações e o tempo médio de permanência. A pergunta é em que condições esses resultados se aproximam das previsões do modelo M/M/1. Para respondê-la, variamos a carga e a duração das execuções e examinamos a variabilidade entre repetições, a conservação do fluxo e os regimes crítico e sobrecarregado. Criamos também uma versão corrigida (V4), que trata problemas de entrada e de encerramento da original (V3) e acrescenta o número e o tempo médio na fila de espera, o comprimento máximo da fila, o tempo de permanência de cada cliente e um período de aquecimento opcional. As duas versões foram comparadas.

A seção 2 apresenta a fundamentação teórica; a seção 3 descreve o código e suas limitações; a seção 4 detalha o experimento; a seção 5 discute os resultados; e a seção 6 traz as considerações finais.

2 Fundamentação teórica

2.1 Processos de chegada e distribuição exponencial

No modelo M/M/1, as chegadas formam um processo de Poisson de taxa $\lambda > 0$. A quantidade $C(t)$ de chegadas em um intervalo de duração t segue a distribuição de Poisson:

$$P\{C(t) = k\} = e^{-\lambda t}\frac{(\lambda t)^k}{k!}, \qquad k = 0, 1, 2, \ldots \quad (1)$$

O parâmetro λ é o número médio de chegadas por unidade de tempo: com $\lambda = 0{,}5$ solicitação por segundo, chega em média uma solicitação a cada dois segundos.

Os intervalos X entre chegadas consecutivas são independentes e exponenciais de taxa λ:

$$F_X(x) = P\{X \le x\} = 1 - e^{-\lambda x}, \qquad x \ge 0, \quad (2)$$

com média E[X] $= 1/\lambda$. Da mesma forma, o tempo de atendimento S é exponencial de taxa μ, com média

$\mathrm{E}[S] = 1/\mu$. A falta de memória da exponencial permite tratar o sistema como um processo markoviano (TRIVEDI, 2001; GONZAGA, 2026).

2.2 Geração de variáveis pela transformada inversa

O simulador gera os intervalos exponenciais pelo método da transformada inversa. A partir de um número pseudoaleatório U uniforme em $(0, 1]$, obtém-se uma amostra exponencial de taxa r por

$$X = -\frac{\ln(U)}{r}. \tag{3}$$

O código usa $r = \lambda$ para a próxima chegada e $r = \mu$ para a duração do atendimento; a função `aleatorio()` fornece U. O programa recebe tempos médios (m_c entre chegadas e m_s de atendimento) e os converte em taxas, $\lambda = 1/m_c$ e $\mu = 1/m_s$. Por isso, depois da conversão, as variáveis `intervalo_chegadas` e `media_atendimento` guardam taxas, apesar dos nomes.

2.3 Notação de Kendall e modelo M/M/1

A notação de Kendall descreve uma fila na forma $A/S/c$: A é a distribuição dos intervalos entre chegadas, S a dos tempos de serviço e c o número de servidores (KENDALL, 1953). Em M/M/1, os dois M indicam distribuições exponenciais e o 1 indica um único servidor.

No código, os dois M correspondem às duas chamadas da transformada inversa (chegadas e saídas), e o servidor único aparece no fato de existir apenas um instante de saída agendado por vez. O programa não guarda as solicitações individualmente, mas, como atende uma de cada vez, o comportamento das medidas agregadas é o de uma fila atendida por ordem de chegada.

2.4 Utilização e condição de estabilidade

A intensidade de tráfego, ou utilização, é

$$\rho = \frac{\lambda}{\mu}. \tag{4}$$

Em uma fila M/M/1 estável, ρ é a fração do tempo em que o servidor está ocupado. Para que exista regime estacionário com médias finitas, é preciso que

$$\lambda < \mu \quad \Longleftrightarrow \quad \rho < 1. \tag{5}$$

Quanto mais ρ se aproxima de 1, menor a folga do servidor e maiores a população, o tempo de permanência e a variabilidade. Para $\rho \geq 1$ não há distribuição estacionária. No caso crítico ($\rho = 1$), o sistema volta a ficar vazio de tempos em tempos, mas não se estabiliza; com $\rho > 1$, a população cresce sem limite. Nesses casos, uma simulação de duração finita ainda produz números, mas eles dependem do horizonte e não são médias de equilíbrio (TRIVEDI, 2001).

2.5 Medidas de desempenho do M/M/1

Seja $N(t)$ o número de solicitações no sistema no instante t, incluindo a que está em atendimento. A média estacionária é $L = \mathrm{E}[N]$ e a média apenas na fila de espera é $L_q = \mathrm{E}[N_q]$. Da mesma forma, $W = \mathrm{E}[W]$ é o tempo médio total no sistema e $W_q = \mathrm{E}[W_q]$ o tempo médio de espera antes do atendimento. Para a fila M/M/1 estável:

$$L = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda}, \qquad L_q = \frac{\rho^2}{1-\rho}, \tag{6}$$

$$W = \frac{1}{\mu - \lambda}, \qquad W_q = \frac{\rho}{\mu - \lambda}. \tag{7}$$

As versões V3 e V4 estimam a ocupação, L e W. A estimativa de L é uma média no tempo; a de W é indireta e inclui permanências cortadas no fim da execução (Seção 3.4). A V4 também estima L_q, W_q e os percentis de W (Seção 3.6).

Além das médias, na M/M/1 com atendimento por ordem de chegada o tempo no sistema W tem distribuição exponencial de taxa $\mu - \lambda$ (TRIVEDI, 2001). Assim, o percentil p de W, isto é, o tempo que uma fração p dos clientes não ultrapassa, é

$$w_p = \frac{-\ln(1-p)}{\mu - \lambda}. \tag{8}$$

A mediana ($p = 0{,}5$) vale cerca de 0,69 vez a média, e o percentil 95 vale cerca de 3 vezes a média.

2.6 Lei de Little

A Lei de Little relaciona o número médio de elementos em um sistema estável, a taxa com que eles passam pelo sistema e o tempo médio de permanência (LITTLE, 1961):

$$L = \lambda_{\mathrm{ef}} W, \qquad L_q = \lambda_{\mathrm{ef}} W_q, \tag{9}$$

em que λ_{ef} é a taxa efetiva de entrada. Sem perdas e em regime estável, $\lambda_{\mathrm{ef}} = \lambda$. Em palavras: o número médio de clientes presentes é igual ao número que chega por unidade de tempo vezes o tempo que cada um fica. A lei vale para qualquer distribuição, não só para a exponencial. No simulador, porém, $\mathrm{E}[N]$ e $\mathrm{E}[W]$ saem das mesmas áreas acumuladas, de modo que o resíduo de Little calculado pelo programa é praticamente zero por construção (Seção 3.4). Por isso, a V4 também mede o tempo de cada cliente diretamente.

3 Análise do simulador em linguagem C

3.1 Visão geral

O arquivo `simulacao_v3.c` é uma simulação a eventos discretos de uma fila com um servidor. O relógio não avança em passos fixos: ele salta direto para a próxima chegada ou saída, o que evita processar períodos em que nada muda (ROSS, 2006).

O programa recebe o tempo médio entre chegadas, o tempo médio de atendimento e a duração da simulação. Durante a execução, mantém o relógio, o número de solicitações no sistema e os instantes da próxima chegada e da próxima saída. No final, imprime ocupação, E[N], E[W] e o resíduo de Little. Três estruturas do tipo `Info` acumulam áreas no tempo: uma para $N(t)$ e duas para os totais acumulados de chegadas e de saídas. Assim, as médias temporais são obtidas sem guardar o histórico do sistema. A Tabela 1 relaciona as grandezas do modelo às variáveis do código.

Tabela 1 – Correspondência entre as grandezas do modelo e as variáveis da V3.

Grandeza	Variável ou acumulador
Relógio t	`tempo_decorrido`
População $N(t)$	`fila` e `en.numero_eventos`
Próxima chegada	`chegada_cliente`
Próxima saída	`saida_cliente`
Taxa λ	`intervalo_chegadas` (após a conversão)
Taxa μ	`media_atendimento` (após a conversão)
Chegadas $A(t)$	`ew_chegadas.numero_eventos`
Saídas $D(t)$	`ew_saidas.numero_eventos`
Área sob $N(t)$	`en.soma_areas`

Fonte: Elaboração própria, a partir do código fornecido.

3.2 Laço de eventos

A variável `fila` guarda a população total, e não só quem espera: zero significa servidor ocioso, um significa uma solicitação em atendimento e valores maiores indicam espera. Com o sistema vazio, o próximo evento só pode ser uma chegada; com o sistema ocupado, é o menor instante entre chegada e saída. Entre dois eventos, em t_{i-1} e t_i, o estado não muda, e o intervalo $t_i - t_{i-1}$ é usado para atualizar as áreas.

Em uma chegada, a população e o contador de chegadas aumentam e a próxima chegada é sorteada. Se o servidor estava ocioso, o atendimento começa na hora e a saída é agendada. Em uma saída, a população diminui e o contador de saídas aumenta; se ainda houver alguém, o próximo atendimento começa e uma nova saída é agendada. Cada iteração do laço, portanto: (i) escolhe o próximo evento; (ii) acumula as áreas até ele; (iii) processa o evento e agenda os seguintes.

Na V3, o evento escolhido é processado mesmo que ocorra depois do horizonte T. Na V4, o limite é verificado antes: se o próximo evento está depois de T, as áreas são fechadas em T e o laço termina.

3.3 Cálculo da ocupação e de E[N]

Na V3, `soma_atendimentos` soma a duração de cada atendimento no instante em que ele começa, e o total é dividido pelo tempo final. Assim, um atendimento que começa antes do horizonte e termina depois dele é contado inteiro, inclusive a parte fora da janela observada. A V4 corrige isso acumulando a área do indicador "servidor ocupado" apenas até T.

O número médio de solicitações é a área sob $N(t)$ dividida pelo tempo observado T_{obs}:

$$\widehat{\mathrm{E}[N]} = \frac{1}{T_{\text{obs}}} \sum_i N_{i-1}(t_i - t_{i-1}). \tag{10}$$

Apesar do nome, `en.numero_eventos` guarda a população atual: ele aumenta nas chegadas e diminui nas saídas.

3.4 Cálculo de E[W] e resíduo de Little

O código não guarda os instantes de chegada e saída de cada solicitação, apenas os totais acumulados $A(t)$ e $D(t)$. Como o sistema começa vazio e não há perdas, $N(t) = A(t) - D(t)$, e portanto

$$\int_0^{T_{\text{obs}}} N(t)\,dt = \int_0^{T_{\text{obs}}} A(t)\,dt - \int_0^{T_{\text{obs}}} D(t)\,dt. \tag{11}$$

O programa divide essa diferença de áreas pelo número de chegadas. Se a_j e d_j são os instantes de chegada e saída da solicitação j, o resultado é

$$\widehat{\mathrm{E}[W]} = \frac{\sum_{j:\, a_j \le T_{\text{obs}}} \big[\min(d_j, T_{\text{obs}}) - a_j\big]}{A(T_{\text{obs}})}. \tag{12}$$

Ou seja, quem ainda está no sistema no final contribui só com o tempo que ficou até T_{obs}. Isso acontece nas duas versões. Em execuções longas de sistemas estáveis, essas poucas permanências cortadas pesam pouco na média.

Como $\widehat{\mathrm{E}[W]} = \int N\,dt / A(T_{\text{obs}})$, $\widehat{\mathrm{E}[N]} = \int N\,dt / T_{\text{obs}}$ e $\hat{\lambda} = A(T_{\text{obs}})/T_{\text{obs}}$, o resíduo $\widehat{\mathrm{E}[N]} - \hat{\lambda}\widehat{\mathrm{E}[W]}$ é zero por construção, a menos de arredondamento. Ele mostra que os acumuladores estão consistentes, mas não testa a Lei de Little de forma independente. Para isso, a V4 mede também o tempo de cada cliente (Seção 3.6).

3.5 Versões utilizadas no experimento

O arquivo original foi mantido. Para as execuções em lote, foi criada a cópia `simulacao_v3_testes.c`, que recebe a semente pela entrada, valida as entradas e imprime as estatísticas em um formato simples, sem as mensagens de cada evento. A lógica dos eventos e os estimadores são os mesmos do original, inclusive o processamento além do horizonte e a soma antecipada dos atendimentos. Nos resultados, "V3" se refere a essa cópia.

A `simulacao_v4.c` mantém o mesmo modelo e as mesmas medidas. Duas de suas mudanças afetam os resultados: o encerramento exatamente em T, com as áreas fechadas nesse instante, e a contagem da

ocupação apenas dentro da janela $[0, T]$. As demais, validação das entradas e proteção contra divisão por zero quando não há chegadas, só tornam o programa mais robusto. Como a cópia de testes da V3 também recebe a semente, as duas versões podem ser executadas com os mesmos números aleatórios, e a comparação entre elas mede apenas o efeito das duas correções.

O script `experimentos_mm1.py` não simula a fila: ele compila e executa os programas em C, organiza as saídas em CSV, calcula médias e intervalos de confiança e gera os gráficos.

3.6 Extensões da V4

A V4 ganhou três medidas que seguem o mesmo padrão de áreas do código original. A quantidade na fila de espera é $N_q(t) = \max(N(t) - 1, 0)$; sua área, dividida pelo tempo observado, dá $\widehat{\mathrm{E}[N_q]}$, e dividida pelo número de chegadas dá $\widehat{\mathrm{E}[W_q]}$. Como no caso de $\mathrm{E}[W]$, a relação $\widehat{\mathrm{E}[N_q]} = \widehat{\lambda}\widehat{\mathrm{E}[W_q]}$ vale por construção. A terceira medida é o comprimento máximo de $N(t)$ durante a observação.

Para medir o tempo de cada cliente sem mudar a estrutura do programa, a V4 guarda os instantes de chegada numa lista, em ordem. Como o atendimento é por ordem de chegada, quem sai é sempre o primeiro da lista, e o seu tempo no sistema é o instante da saída menos o da chegada. Entram nessa conta apenas os clientes que chegaram e saíram dentro da janela observada. No final, o programa calcula a média desses tempos, chamada aqui de W direto, e ordena a lista para obter a mediana (P50) e o percentil 95 (P95). Como esse W não vem das áreas, a relação $\widehat{\mathrm{E}[N]} = \widehat{\lambda}\widehat{W}$ deixa de valer por construção e passa a ser um teste de verdade.

A V4 também aceita um quinto valor de entrada, opcional: o tempo de aquecimento T_a. Quando a simulação passa de T_a, todas as áreas e contadores são zerados e a coleta recomeça, de modo que as medidas descrevem só a janela $[T_a, T]$. As solicitações já presentes nesse instante são contadas como chegadas da janela no acumulador de chegadas, para que a diferença entre as áreas de chegadas e saídas continue igual a $N(t)$, mas ficam fora do denominador de $\widehat{\mathrm{E}[W]}$ e $\widehat{\lambda}$. Sem o quinto valor, $T_a = 0$, e as medidas originais saem idênticas às da V4 sem as extensões; isso foi conferido nas 1.200 execuções do experimento principal.

3.7 Limitações

No experimento principal, as execuções começam com o sistema vazio e não descartam aquecimento; o efeito do descarte foi avaliado em um experimento separado. Na V3, o tempo de permanência só é obtido de forma indireta, com as permanências cortadas no fim; a V4 contorna isso medindo o tempo de cada cliente.

O gerador `rand()` produz inteiros em um conjunto finito, de modo que U assume valores em uma grade, e não em um intervalo contínuo. Sua qualidade depende da biblioteca C utilizada. A aderência das amostras à exponencial não foi testada, mas a boa concordância com a teoria nos cenários estáveis não sugere problemas causados pelo gerador.

4 Metodologia

4.1 Cenários e valores teóricos

A taxa de atendimento foi fixada em $\mu = 1$ solicitação por segundo, e a carga foi controlada pela taxa de chegada. Com $\mu = 1$, tem-se $\lambda = \rho$. Os cenários foram escolhidos para cobrir desde uma carga baixa até a saturação, com mais pontos perto de $\rho = 1$, onde o comportamento muda mais rápido. Antes de simular, os valores teóricos de cada cenário estável foram calculados pelas Equações 6 e 7 (Tabela 2). C7 ($\rho = 1$) e C8 ($\rho = 1{,}1$) não têm regime estacionário e foram incluídos para observar o que acontece quando a condição de estabilidade é violada.

Tabela 2 – Cenários avaliados e valores teóricos calculados antes da simulação ($\mu = 1$, $\lambda = \rho$).

Cenário	ρ	$\mathrm{E}[N]$	$\mathrm{E}[W]$	$\mathrm{E}[N_q]$	$\mathrm{E}[W_q]$
C1	0,25	0,333	1,333	0,083	0,333
C2	0,50	1,000	2,000	0,500	1,000
C3	0,75	3,000	4,000	2,250	3,000
C4	0,90	9,000	10,000	8,100	9,000
C5	0,95	19,000	20,000	18,050	19,000
C6	0,99	99,000	100,000	98,010	99,000
C7	1,00	–	–	–	–
C8	1,10	–	–	–	–

Fonte: Elaboração própria.

A tabela já mostra por que a região perto de $\rho = 1$ é a mais delicada. O que determina o tempo no sistema é a folga do servidor, $1 - \rho$, e não a carga em si: como $\mathrm{E}[W] = 1/(\mu - \lambda)$, quando a folga cai de 0,10 ($\rho = 0{,}90$) para 0,01 ($\rho = 0{,}99$), $\mathrm{E}[W]$ fica dez vezes maior, passando de 10 para 100 segundos.

4.2 Horizontes, repetições e sementes

Uma simulação de duração finita só se aproxima da média de longo prazo, e essa aproximação melhora com a duração. Para observar esse efeito, cada cenário foi executado com cinco horizontes, de $T = 10^2$ a $T = 10^6$ segundos. O maior horizonte foi incluído por causa do cenário C6: o tempo que a fila leva para "esquecer" o estado inicial cresce com $(1 - \rho)^{-2}$ (MORSE, 1955) e, de $\rho = 0{,}90$ para $\rho = 0{,}99$, fica cerca de cem vezes maior.

Cada combinação de cenário e horizonte foi repetida 30 vezes, com sementes diferentes. Como cada repetição é independente das outras, as 30 médias permi-

tem estimar a incerteza do resultado por meio de um intervalo de confiança. No total, foram $8 \times 5 \times 30 = 1.200$ execuções por versão.

As duas versões receberam exatamente as mesmas sementes. Como V3 e V4 sorteiam os números aleatórios na mesma ordem, cada par de execuções percorre a mesma trajetória até o horizonte, e qualquer diferença entre elas vem apenas das correções da V4. Todas essas execuções começaram com o sistema vazio.

4.3 Experimento de aquecimento

Como o sistema começa vazio, os primeiros instantes de cada execução não representam o regime estacionário. Uma forma de contornar isso é descartar um período inicial, chamado de aquecimento, e só depois começar a medir. Para avaliar esse efeito, a V4 foi executada em C4, C5 e C6 com uma janela de medição fixa de 10^4 segundos, precedida de aquecimentos de 0, 10^3, 10^4 e 10^5 segundos. A janela curta foi escolhida de propósito, porque é nela que o viés do início vazio aparece com mais força. Foram usadas 200 repetições por combinação: com 30, os resultados de C6 mudavam muito conforme o conjunto de sementes.

4.4 Tratamento estatístico

Para cada conjunto de R repetições, calculou-se a média e o intervalo de confiança (IC) de 95% pela distribuição t de Student:

$$\bar{x} \pm t_{0,975;R-1} \frac{s}{\sqrt{R}}. \tag{13}$$

O IC indica a faixa em que, com 95% de confiança, está a média que o simulador produziria com infinitas repetições. Se o valor teórico cai dentro do IC, a diferença entre simulação e teoria pode ser explicada pela aleatoriedade; se cai fora, há indício de um erro sistemático. A distância até a teoria foi medida pelo erro relativo:

$$\text{Erro (\%)} = 100 \left| \frac{\text{simulado} - \text{teórico}}{\text{teórico}} \right|. \tag{14}$$

Como os cenários têm escalas muito diferentes ($\mathrm{E}[N]$ vai de 0,33 a 99), várias figuras mostram a média dividida pelo valor teórico: um valor igual a 1 significa concordância exata. As figuras mostram apenas $\mathrm{E}[N]$ porque o simulador calcula $\widehat{\mathrm{E}[W]} = \widehat{\mathrm{E}[N]}/\widehat{\lambda}$ (Seção 3.4), e por isso os erros de $\mathrm{E}[W]$ acompanham os de $\mathrm{E}[N]$.

Na comparação entre versões, calculou-se a diferença V3−V4 em cada par de execuções com a mesma semente e aplicou-se o IC da Equação 13 a essas diferenças. Um IC que contém zero indica que as versões não se distinguem.

4.5 Ambiente e reprodução

Os simuladores foram compilados com GCC 15.2.0 (`-O2 -std=c11 -Wall -Wextra -lm`). O script `experimentos_mm1.py` (Python 3.14.4, Matplotlib 3.10.7 e SciPy 1.16.3) executa todas as combinações, salva os CSVs e gera as figuras. Os códigos, os dados de cada execução e as instruções de reprodução estão em `https://github.com/JeannVictor/Trabalho_1_Analise_Desempenho`.

5 Resultados e discussão

5.1 Teoria e simulação

O primeiro objetivo era verificar se o simulador reproduz a teoria quando tem tempo suficiente. A Tabela 3 compara os valores teóricos com as médias de $T = 10^6$. Nesse horizonte, V3 e V4 coincidem até a quarta casa decimal (Seção 5.6), e por isso a tabela traz uma única média.

O simulador reproduziu a teoria em todos os cenários estáveis. A ocupação teve erro abaixo de 0,1% em todos eles. Para $\mathrm{E}[N]$ e $\mathrm{E}[W]$, o erro ficou abaixo de 0,3% até $\rho = 0{,}90$ e entre 1,1% e 1,7% em C5 e C6, e o valor teórico ficou dentro do IC em todos os casos. A única medida fora do IC foi a ocupação de C5, por uma margem pequena (0,9498 contra 0,95); com 18 intervalos de 95%, espera-se cerca de um fora apenas por acaso.

O erro cresce perto da saturação porque a fila passa longos períodos acumulada ou vazia, e uma execução contém poucos desses períodos. As médias variam mais de uma execução para outra e o IC fica mais largo. É por isso que o horizonte de 10^6 foi necessário: com $T = 10^5$, o IC de $\mathrm{E}[N]$ em C4 não continha a teoria, e o de C6 tinha semiamplitude de 20% da média, contra 6% em $T = 10^6$.

Na Figura 1, a mesma comparação aparece em forma de curva. Com $T = 10^6$, todos os pontos caem sobre a curva teórica; com $T = 10^4$, o ponto de $\rho = 0{,}99$ fica bem abaixo dela, efeito que explicamos na seção seguinte.

5.2 Influência do horizonte de simulação

A Figura 2 mostra como as estimativas mudam com o horizonte. Nas cargas baixas (C1 e C2), elas ficam perto da teoria desde os horizontes curtos. Nas cargas altas, os horizontes curtos ficam sistematicamente abaixo da teoria, e o efeito piora com ρ: em $T = 10^2$, $\mathrm{E}[N]$ ficou em 61% do valor teórico em C4, 27% em C5 e apenas 6% em C6.

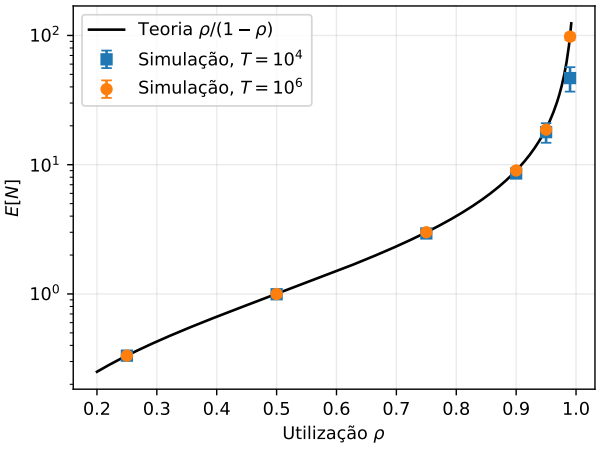
A causa é o início vazio. Em C6, a fila típica do regime estacionário tem 99 solicitações, mas a simulação começa com zero. Com o servidor ocupado, sai em média apenas 0,01 solicitação por segundo a mais do que entra, então a fila quase não tem tendência de subir nem de descer. Ela só chega ao nível típico por

Tabela 3 – Resultados nos cenários estáveis para $T = 10^6$ (30 repetições).

Cenário	Medida	Teórico	Média simulada (V3 = V4)	IC de 95% (V4)	Erro (%)
C1	Ocupação	0,2500	0,2499	[0,2497; 0,2502]	0,023
C1	E[N]	0,3333	0,3333	[0,3328; 0,3337]	0,022
C1	E[W]	1,3333	1,3333	[1,3315; 1,3350]	0,006
C2	Ocupação	0,5000	0,4997	[0,4994; 0,5000]	0,055
C2	E[N]	1,0000	0,9986	[0,9968; 1,0004]	0,139
C2	E[W]	2,0000	1,9977	[1,9944; 2,0009]	0,117
C3	Ocupação	0,7500	0,7499	[0,7496; 0,7503]	0,008
C3	E[N]	3,0000	3,0017	[2,9922; 3,0112]	0,057
C3	E[W]	4,0000	4,0034	[3,9910; 4,0158]	0,084
C4	Ocupação	0,9000	0,9000	[0,8995; 0,9004]	0,005
C4	E[N]	9,0000	9,0215	[8,9656; 9,0775]	0,239
C4	E[W]	10,0000	10,0263	[9,9657; 10,0868]	0,263
C5	Ocupação	0,9500	0,9492	[0,9486; 0,9498]	0,084
C5	E[N]	19,0000	18,6843	[18,3500; 19,0185]	1,662
C5	E[W]	20,0000	19,6735	[19,3260; 20,0210]	1,633
C6	Ocupação	0,9900	0,9899	[0,9894; 0,9905]	0,008
C6	E[N]	99,0000	97,8988	[91,9794; 103,8181]	1,112
C6	E[W]	100,0000	98,8953	[92,9277; 104,8630]	1,105

Fonte: Elaboração própria.

Figura 1 – E[N] teórico (curva) e médias simuladas pela V4 com IC de 95%, para $T = 10^4$ e $T = 10^6$; escala logarítmica.

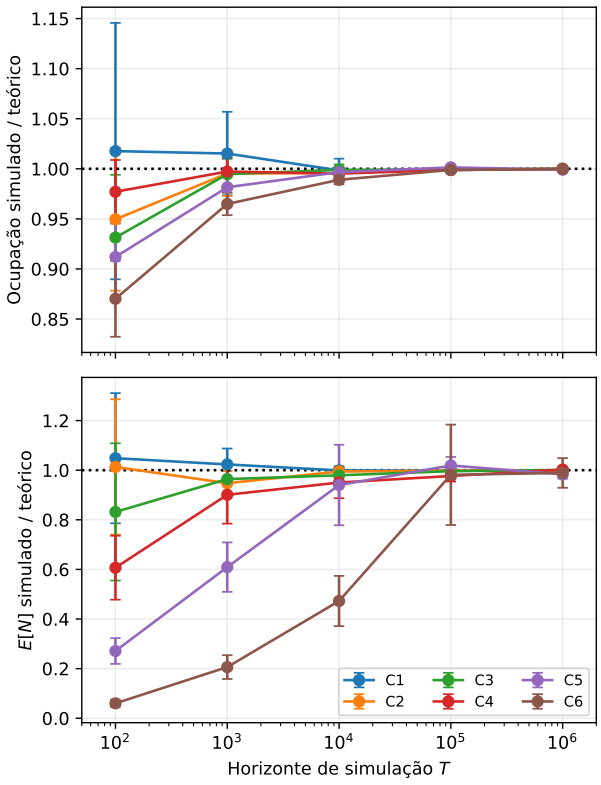


Fonte: Elaboração própria.

meio de flutuações aleatórias, o que leva muito tempo, e todo esse período de enchimento entra na média. Em C6, a estimativa chegou a 47% da teoria em $T = 10^4$ e só se aproximou dela a partir de $T = 10^5$.

Esse erro é um viés, e não uma flutuação aleatória: mais repetições estreitariam o IC em torno do valor errado, sem corrigi-lo. A duração necessária, portanto, depende da carga, e um horizonte suficiente para $\rho = 0{,}75$ pode ser muito curto para $\rho = 0{,}99$.

Figura 2 – Ocupação e E[N] da V4 divididos pelo valor teórico, em função do horizonte, com ICs de 95%.

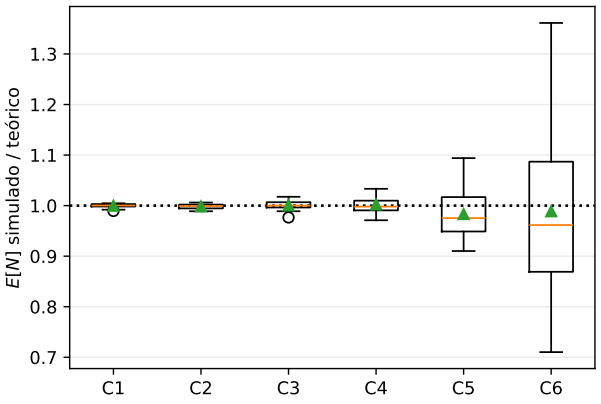


Fonte: Elaboração própria.

5.3 Variabilidade entre repetições

O IC descreve a incerteza da média de 30 execuções. Para saber quanto uma execução isolada pode errar, a Figura 3 mostra a distribuição das 30 estimativas de E[N] com $T = 10^6$.

Figura 3 – Estimativas de E[N] divididas pelo valor teórico nas 30 execuções (V4, $T = 10^6$). A caixa vai do 1º ao 3º quartil, a linha interna é a mediana e o triângulo é a média.



Fonte: Elaboração própria.

De C1 a C4, todas as execuções ficaram a menos de 4% da teoria. Em C5, a variação chegou a cerca de 10% e, em C6, as estimativas foram de 0,71 a 1,36 vez o valor teórico. Ou seja, mesmo com um milhão de segundos simulados, uma única execução com $\rho = 0{,}99$ pode errar E[N] em mais de 30%. Perto da saturação, conclusões confiáveis exigem várias repetições.

5.4 Vazão e verificações de consistência

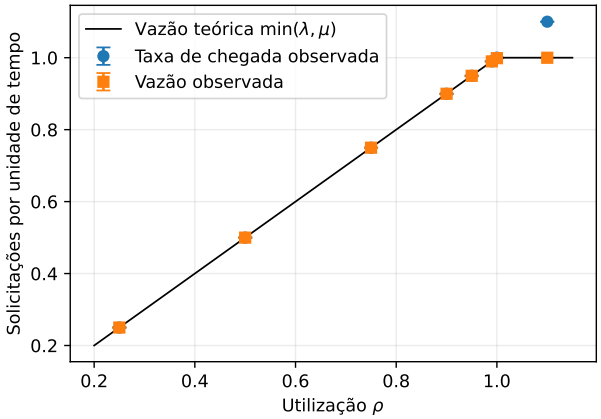
Um servidor não consegue atender mais do que μ solicitações por segundo. A vazão de longo prazo é, portanto, $\min(\lambda, \mu)$: igual à taxa de chegada quando o sistema é estável e igual à capacidade quando ele está sobrecarregado. A Figura 4 confirma isso. Em C8, chegaram em média 1,1001 solicitações por segundo e saíram 0,9998; a diferença se acumula na fila.

Como as execuções começam vazias, o número de solicitações no final deve ser exatamente o número de chegadas menos o de saídas:

$$(\widehat{\lambda} - \widehat{v})\, T_{\text{obs}} = A(T_{\text{obs}}) - D(T_{\text{obs}}) = N(T_{\text{obs}}), \quad (15)$$

em que $\widehat{v}$ é a vazão observada. Essa igualdade valeu nas 2.400 execuções, com diferença máxima abaixo de 10^{-6}, que vem apenas do arredondamento das saídas. Ela confirma que nenhuma solicitação foi criada ou perdida pelo código. Já o resíduo de Little calculado pelas áreas ficou abaixo de 6×10^{-8}, mas, como explicado na Seção 3.4, ele é nulo por construção e não acrescenta evidência. A verificação independente da lei é feita na Seção 5.8.

Figura 4 – Taxa de chegada observada, vazão da V4 e vazão teórica $\min(\lambda, \mu)$ para $T = 10^6$.

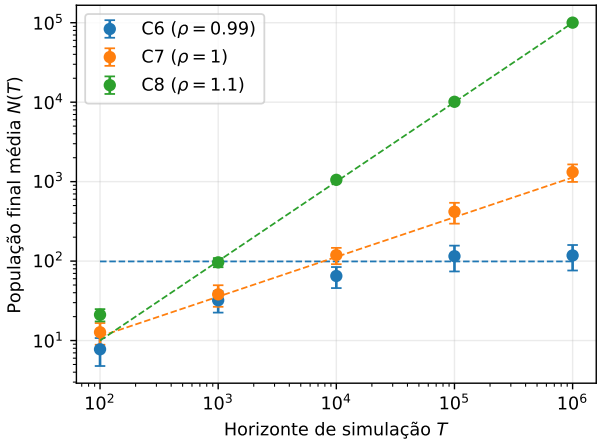


Fonte: Elaboração própria.

5.5 Cenários crítico e sobrecarregado

A Figura 5 mostra o que acontece com a população final quando o horizonte cresce, comparando C6, que é estável, com C7 e C8, que não são.

Figura 5 – População final média da V4 em função do horizonte, com ICs de 95%. Tracejado: $\rho/(1-\rho)$ para C6, $\sqrt{4T/\pi}$ para C7 e $(\lambda - \mu)T$ para C8.



Fonte: Elaboração própria.

Os três cenários se comportam de maneiras diferentes, e cada um segue sua previsão. Em C6 ($\rho = 0{,}99$), a população para de crescer e se estabiliza em torno de E[N] = 99, como esperado de um sistema estável. Em C8 ($\rho = 1{,}1$), chegam 0,1 solicitação por segundo a mais do que o servidor consegue atender, e esse excesso se acumula: a população cresce linearmente, segundo $(\lambda - \mu)T$, e chegou a 100.250 em $T = 10^6$, contra 100.000 previstos.

Em C7 ($\rho = 1$), entra, em média, o mesmo número de solicitações que sai, então não há acúmulo sistemático. A população, porém, se comporta como

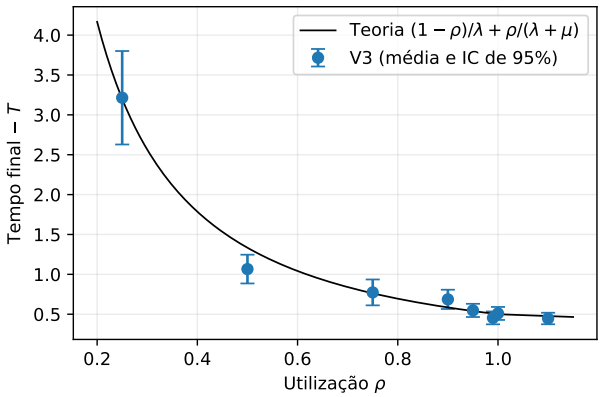
um passeio aleatório: sobe e desce ao acaso e, como não há folga para trazê-la de volta, vai se afastando de zero. Esse afastamento cresce com a raiz do tempo, na média $\sqrt{4T/\pi} \approx 1{,}13\sqrt{T}$. Os valores observados ficaram entre $1{,}2\sqrt{T}$ e $1{,}3\sqrt{T}$, compatíveis com a previsão dentro da incerteza das 30 repetições.

Nos cenários C7 e C8, a população não se estabiliza, então as médias de E[N] e E[W] dependem do horizonte e não representam um regime de equilíbrio.

5.6 Comparação entre V3 e V4

A V3 só encerra depois de processar o primeiro evento posterior ao horizonte, então o seu tempo final sempre passa de T. A falta de memória da exponencial permite prever esse excesso: se o servidor está ocioso em T, o próximo evento só pode ser uma chegada, que demora em média $1/\lambda$; se está ocupado, ele pode ser uma chegada ou uma saída, e demora em média $1/(\lambda+\mu)$. Ponderando pela ocupação, o excesso médio é $(1-\rho)/\lambda + \rho/(\lambda+\mu)$. Como esse valor não depende de T, os cinco horizontes foram reunidos na Figura 6.

Figura 6 – Excesso médio do tempo final da V3 sobre o horizonte, reunindo os cinco horizontes, e previsão teórica.



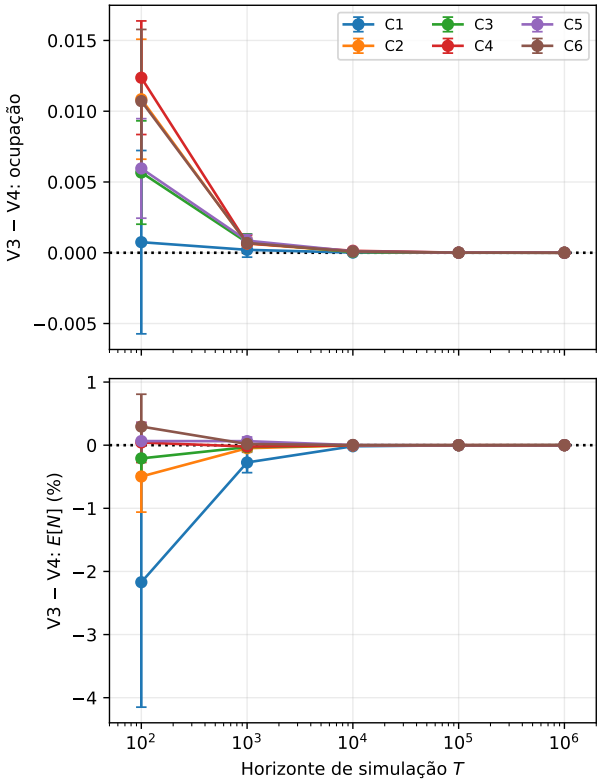
Fonte: Elaboração própria.

As médias seguem a previsão: cerca de 3,2 segundos em C1, onde o servidor fica ocioso na maior parte do tempo, e cerca de 0,5 segundo nas cargas altas. Como o excesso tem tamanho fixo, o seu peso diminui à medida que o horizonte cresce.

A Figura 7 mostra o efeito disso sobre as medidas. Em $T = 10^2$, a ocupação da V3 foi maior que a da V4 em todos os cenários, em até 0,012. O motivo é que a V3 soma a duração de cada atendimento no momento em que ele começa, inclusive a parte que termina depois de T. Em E[N], as diferenças não têm um sinal definido e ficaram, em média, em 1,2% em $T = 10^2$. A partir de $T = 10^4$, as duas versões praticamente coincidem: a diferença em E[N] fica abaixo de 0,03%.

A lógica central da V3 está correta, e seus problemas estão apenas na fronteira da janela de observação,

Figura 7 – Diferença pareada V3−V4 nos cenários estáveis, com ICs de 95%: absoluta para a ocupação e relativa para E[N].



Fonte: Elaboração própria.

onde só pesam nas execuções curtas. A V4 é preferível por medir exatamente o intervalo $[0, T]$, mas, nos horizontes usados para comparar com a teoria, as duas versões levam às mesmas conclusões.

5.7 Medidas adicionais da V4

Este subitem e os dois seguintes tratam do que só a V4 mede. A Tabela 4 traz a fila de espera e o comprimento máximo da fila.

E[N_q] e E[W_q] seguiram a teoria com a mesma precisão de E[N], e a teoria ficou dentro do IC em todos os cenários. Isso decorre de um fato simples: sempre que o servidor está ocupado, $N(t) = N_q(t) + 1$, e a ocupação é estimada com erro abaixo de 0,1%, de modo que os erros da fila de espera são praticamente os mesmos do sistema completo.

O comprimento máximo da fila se comporta de outro jeito: ele não converge, mas cresce com a duração da simulação. Quanto mais longa a observação, maior a chance de ocorrer um congestionamento raro. O máximo também fica muito acima da média: em C3, onde E[N] = 3, a fila chegou em média a 39 solicitações em $T = 10^6$. Então o máximo só faz sentido junto com a duração da observação, e dimensionar um sistema pela média subestimaria os seus picos.

Tabela 4 – Medidas adicionais da V4: fila de espera para $T = 10^6$ e comprimento máximo médio da fila para dois horizontes (30 repetições).

	$\mathrm{E}[N_q]$			$\mathrm{E}[W_q]$			Fila máxima	
Cenário	Teórico	Simulado	Erro (%)	Teórico	Simulado	Erro (%)	$T = 10^4$	$T = 10^6$
C1	0,0833	0,0833	0,018	0,3333	0,3333	0,002	6,3	9,5
C2	0,5000	0,4989	0,223	1,0000	0,9980	0,201	11,8	18,4
C3	2,2500	2,2518	0,079	3,0000	3,0032	0,106	23,0	38,7
C4	8,1000	8,1216	0,267	9,0000	9,0261	0,290	47,0	95,6
C5	18,0500	17,7351	1,745	19,0000	18,6740	1,716	72,9	159,1
C6	98,0100	96,9088	1,124	99,0000	97,8953	1,116	130,4	533,8

Fonte: Elaboração própria.

5.8 Lei de Little com tempos individuais e percentis

Até aqui, a Lei de Little não pôde ser testada, porque o resíduo calculado a partir das áreas é zero de qualquer forma. Com o tempo de cada cliente medido diretamente, a situação muda: $\widehat{\mathrm{E}[N]}$ continua vindo da área sob $N(t)$, mas W passa a ser a média dos tempos que cada cliente realmente passou no sistema. Se as duas medidas estiverem corretas, $\widehat{\lambda}\,\widehat{W}$ deve reproduzir $\widehat{\mathrm{E}[N]}$. A Tabela 5 mostra o resultado.

A lei se confirmou. Em $T = 10^6$, a diferença entre $\widehat{\mathrm{E}[N]}$ e $\widehat{\lambda}\,\widehat{W}$ ficou abaixo de 0,002% em todos os cenários estáveis. Em $T = 10^2$ ela chegava a 2%. Essa diferença vem da borda da janela: os clientes que ainda estão no sistema no fim da execução entram na área sob $N(t)$, mas não na média dos tempos individuais, e numa janela curta eles pesam mais. Quanto mais longa a janela, menor o peso dessa borda. O W direto também ficou praticamente igual ao indireto em $T = 10^6$, com diferença máxima de 0,001 em C6, o que mostra que o corte das permanências no fim da execução (Seção 3.4) não afetou os resultados dos horizontes longos.

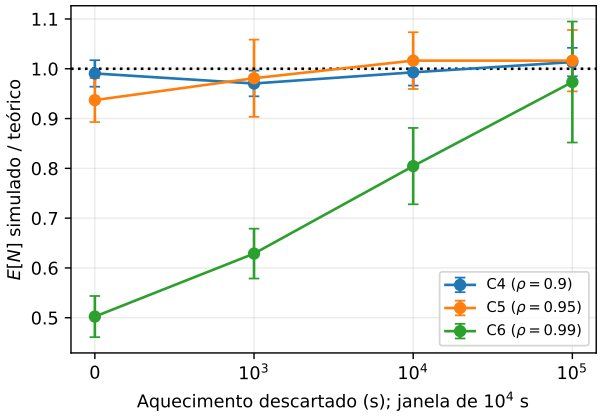
Nos percentis, os valores simulados seguiram a exponencial prevista pela Equação 8: o P50 ficou a menos de 2% da teoria e o P95 a menos de 3%, com a teoria dentro do IC em quase todos os casos (a exceção foi o P50 de C5, a 2% da teoria). Em C4, por exemplo, o tempo médio no sistema é de 10 segundos, mas metade dos clientes fica menos de 7 segundos e um em cada vinte fica mais de 30. Quem avalia o sistema só pela média não enxerga a experiência de quem mais espera.

5.9 Efeito do aquecimento

Na Seção 5.2, o início vazio fez os horizontes curtos subestimarem a teoria. Se essa é mesmo a causa, descartar o período inicial deve resolver o problema. A Figura 8 mostra o resultado do experimento de aquecimento.

Em C6, sem aquecimento, a janela de 10^4 segundos estimou 50% do valor teórico. Descartando 10^3, 10^4 e 10^5 segundos, a estimativa subiu para 63%, 81% e 97%, e só no último caso o IC passou a conter a teoria. Em C5, o pequeno viés sem aquecimento (94%) desapareceu com qualquer descarte, e em C4 a janela de 10^4 segundos já era suficiente.

Figura 8 – $\mathrm{E}[N]$ da V4 dividido pelo valor teórico numa janela de 10^4 s, em função do aquecimento descartado (200 repetições, ICs de 95%).



Fonte: Elaboração própria.

O aquecimento remove o viés, mas não reduz a incerteza. Em C6, a semiamplitude do IC passou de 8% para 12% da média, porque a janela deixa de começar sempre do mesmo estado (vazio) e passa a começar de estados variados, típicos do regime estacionário. Nas cargas muito altas, portanto, o aquecimento precisa ser combinado com uma janela de medição longa.

6 Considerações finais

O objetivo deste trabalho era verificar em que condições o simulador da disciplina reproduz o modelo M/M/1. A resposta é que ele o reproduz bem em todos os cenários estáveis, desde que a simulação dure o suficiente. Com $T = 10^6$, os erros de $\mathrm{E}[N]$ e $\mathrm{E}[W]$ ficaram abaixo de 0,3% até $\rho = 0{,}90$ e abaixo de 2% em $\rho = 0{,}95$ e 0,99, sempre com a teoria dentro do intervalo de confiança. A vazão seguiu $\min(\lambda, \mu)$,

Tabela 5 – Tempo de permanência medido cliente a cliente pela V4 para $T = 10^6$ (30 repetições). "Dif. de Little" é $100\,(\widehat{\mathrm{E}[N]} - \widehat{\lambda}\widehat{W})/\widehat{\mathrm{E}[N]}$, com W direto.

	E[W]				P50 de W		P95 de W	
Cenário	Teórico	Indireto	Direto	Dif. de Little (%)	Teórico	Simulado	Teórico	Simulado
C1	1,3333	1,3333	1,3333	0,0001	0,92	0,92	3,99	4,00
C2	2,0000	1,9977	1,9977	−0,0001	1,39	1,39	5,99	5,98
C3	4,0000	4,0034	4,0034	0,0000	2,77	2,77	11,98	12,00
C4	10,0000	10,0263	10,0263	−0,0001	6,93	6,93	29,96	30,13
C5	20,0000	19,6735	19,6734	0,0002	13,86	13,59	59,91	59,26
C6	100,0000	98,8953	98,8943	0,0015	69,31	68,75	299,57	308,35

Fonte: Elaboração própria.

e a conservação do fluxo foi respeitada em todas as execuções.

Essa duração, porém, depende muito da carga. Como a simulação começa com o sistema vazio, o período de enchimento da fila puxa as médias para baixo, e esse efeito cresce muito perto da saturação: com $\rho = 0{,}99$, mesmo $T = 10^4$ estimou menos da metade do valor teórico, enquanto com $\rho = 0{,}25$ um horizonte de 10^2 já ficava próximo da teoria. Descartar um período de aquecimento corrige esse viés, mas não diminui a variação entre execuções, que nessa carga continua alta. Na prática, quanto mais perto de $\rho = 1$, mais longas e mais numerosas precisam ser as execuções para que o resultado seja confiável.

Quando $\rho \geq 1$, os resultados confirmam que não há regime estacionário: no caso crítico a fila cresceu com a raiz do tempo e, no sobrecarregado, linearmente, com a vazão presa à capacidade do servidor. Nesses casos, as médias simuladas só descrevem a janela observada e não podem ser comparadas com as fórmulas de regime estacionário.

A comparação entre as versões mostrou que a lógica da V3 está correta. Seus problemas, o tempo final que passa do horizonte e a ocupação contada antes da hora, só alteram os resultados nas execuções curtas e desaparecem a partir de $T = 10^4$. A V4 corrige essas falhas e, com as extensões, permitiu ir além das médias. A fila de espera seguiu a teoria com a mesma precisão do sistema completo, a Lei de Little foi confirmada com tempos medidos cliente a cliente, e os percentis e a fila máxima mostraram que a média esconde os piores casos.

Ficam como limitações o gerador `rand()`, cuja qualidade não foi testada, e o fato de o aquecimento ter sido avaliado apenas em três cenários e com uma janela curta.

Referências

GONZAGA, Flávio Barbieri. **Análise de desempenho: aulas 1 a 7**. Alfenas: Universidade Federal de Alfenas, 2026. Material didático em slides.

KENDALL, David G. Stochastic processes occurring in the theory of queues and their analysis by the method of the imbedded Markov chain. **The Annals of Mathematical Statistics**, v. 24, n. 3, p. 338–354, 1953. DOI: `https://doi.org/10.1214/aoms/1177728975`.

LITTLE, John D. C. A proof for the queuing formula: $L = \lambda W$. **Operations Research**, v. 9, n. 3, p. 383–387, 1961. DOI: `https://doi.org/10.1287/opre.9.3.383`.

MORSE, Philip M. Stochastic properties of waiting lines. **Operations Research**, v. 3, n. 3, p. 255–261, 1955. DOI: `https://doi.org/10.1287/opre.3.3.255`.

ROSS, Sheldon M. **Simulation**. 4. ed. San Diego: Academic Press, 2006.

TRIVEDI, Kishor S. **Probability and statistics with reliability, queuing, and computer science applications**. 2. ed. New York: John Wiley & Sons, 2001.