MODELAGEM E SIMULAÇÃO DE UMA FILA M/M/1: ANÁLISE DE DESEMPENHO EM DIFERENTES CENÁRIOS

Jeann Victor Batista
Thallysson Luis Teixeira Carvalho
Universidade Federal de Alfenas – UNIFAL-MG
Bacharelado em Ciência da Computação – Análise de Desempenho
Professor: Flávio Barbieri Gonzaga

Resumo

Este trabalho analisa um simulador a eventos discretos de uma fila M/M/1 escrito em C e relaciona seu funcionamento à notação de Kendall, à condição de estabilidade e à Lei de Little. Foram simulados oito cenários, com intensidade de tráfego entre 0,25 e 1,10, cinco horizontes (de 10^2 a 10^6) e 30 repetições por configuração, o que dá 1.200 execuções da versão original e 1.200 de uma versão corrigida. Os valores teóricos foram calculados antes das simulações e comparados às médias por meio de intervalos de confiança; também foram verificados a conservação do fluxo e as diferenças pareadas entre as versões. Com $T = 10^6$ nos cenários estáveis, os erros relativos de E[N] e E[W] ficaram abaixo de 0,3% até $\rho = 0{,}90$ e entre 1,1% e 1,7% para $\rho = 0{,}95$ e $\rho = 0{,}99$. Neste último, horizontes de até 10^4 estimaram menos da metade do valor teórico. A versão corrigida passou a estimar também E[N_q], E[W_q] e o comprimento máximo da fila, e aceita um período de aquecimento opcional: com $\rho = 0{,}99$ e janela de 10^4, descartar os primeiros 10^5 segundos elevou a estimativa de E[N] de 50% para 97% do valor teórico. Nos cenários crítico e sobrecarregado, a população final cresceu e a vazão ficou próxima da capacidade do servidor. A versão original ultrapassa o horizonte solicitado, mas isso só pesa nas execuções curtas. Com o tempo de cada cliente medido diretamente, E[N] e λW diferiram menos de 0,002% em $T = 10^6$, e os percentis do tempo de permanência seguiram a exponencial prevista.

Palavras-chave: teoria de filas; simulação a eventos discretos; M/M/1; Lei de Little; análise de desempenho.

1 Introdução

Em servidores, roteadores, processadores e discos, uma solicitação às vezes chega com o recurso ocupado e precisa esperar. O que se quer saber é como a carga muda a utilização do recurso, o número de solicitações presentes e o tempo até cada uma ser concluída.

A teoria de filas dá fórmulas fechadas para essas medidas, mas só quando certas hipóteses valem. A simulação a eventos discretos reproduz o sistema no computador e permite observá-lo mesmo fora dessas hipóteses. O caso clássico é a fila M/M/1, com chegadas e atendimentos exponenciais e um único servidor (TRIVEDI, 2001). Comparar as duas abordagens também ajuda a encontrar erros de implementação (ROSS, 2006).

Essa comparação tem uma dificuldade prática. As fórmulas descrevem o regime estacionário, enquanto uma simulação dura um tempo finito e, no nosso caso, começa com o sistema vazio. Com o servidor ocupado 99% do tempo, a teoria prevê 99 solicitações no sistema em média, e nossas execuções de 10^4 segundos estimaram 47.

Este trabalho parte do arquivo `simulacao_v3.c`, fornecido na disciplina. O programa gera chegadas e saídas, controla quantas solicitações estão no sistema e calcula a ocupação, o número médio de solicitações e o tempo médio de permanência. A pergunta é em que condições esses resultados se aproximam das previsões do modelo M/M/1. Para respondê-la, variamos a carga e a duração das execuções e examinamos a variabilidade entre repetições, a conservação do fluxo e os regimes crítico e sobrecarregado. Criamos também uma versão corrigida (V4), que trata problemas de entrada e de encerramento da original (V3) e acrescenta o número e o tempo médio na fila de espera, o comprimento máximo da fila, o tempo de permanência de cada cliente e um período de aquecimento opcional. As duas versões foram comparadas.

A seção 2 apresenta a fundamentação teórica; a seção 3 descreve o código e suas limitações; a seção 4 detalha o experimento; a seção 5 discute os resultados; e a seção 6 traz as considerações finais.

2 Fundamentação teórica

2.1 Processos de chegada e distribuição exponencial

No modelo M/M/1, as chegadas formam um processo de Poisson de taxa $\lambda > 0$. A quantidade $C(t)$ de chegadas em um intervalo de duração t segue a distribuição de Poisson:

$$P\{C(t) = k\} = e^{-\lambda t}\frac{(\lambda t)^k}{k!}, \qquad k = 0, 1, 2, \ldots \quad (1)$$

O parâmetro λ é o número médio de chegadas por unidade de tempo. Com $\lambda = 0{,}5$ solicitação por segundo, chega em média uma solicitação a cada dois segundos.

Os intervalos X entre chegadas consecutivas são independentes e exponenciais de taxa λ:

$$F_X(x) = P\{X \le x\} = 1 - e^{-\lambda x}, \qquad x \ge 0, \quad (2)$$

com média $\mathrm{E}[X] = 1/\lambda$. Da mesma forma, o tempo de atendimento S é exponencial de taxa μ, com média $\mathrm{E}[S] = 1/\mu$. A exponencial não tem memória (o tempo que falta até o próximo evento não depende de quanto já se esperou), e isso permite tratar o sistema como um processo markoviano (TRIVEDI, 2001; GONZAGA, 2026).

2.2 Geração de variáveis pela transformada inversa

O simulador gera os intervalos exponenciais pelo método da transformada inversa. A partir de um número pseudoaleatório U uniforme em $(0, 1]$, obtém-se uma amostra exponencial de taxa r por

$$X = -\frac{\ln(U)}{r}. \quad (3)$$

O código usa $r = \lambda$ para a próxima chegada e $r = \mu$ para a duração do atendimento; a função `aleatorio()` fornece U. O programa recebe tempos médios (m_c entre chegadas e m_s de atendimento) e os converte em taxas, $\lambda = 1/m_c$ e $\mu = 1/m_s$. Por isso, depois da conversão, as variáveis `intervalo_chegadas` e `media_atendimento` guardam taxas, apesar dos nomes.

2.3 Notação de Kendall e modelo M/M/1

A notação proposta por David Kendall em 1953 descreve uma fila na forma $A/S/c$: A é a distribuição dos intervalos entre chegadas, S a dos tempos de serviço e c o número de servidores (KENDALL, 1953). Em M/M/1, os dois M (de markoviano) indicam distribuições exponenciais e o 1 indica um único servidor.

No código, os dois M correspondem aos dois usos da transformada inversa (chegadas e saídas), e o servidor único aparece no fato de existir apenas um instante de saída agendado por vez. O programa não guarda as solicitações individualmente, mas atende uma de cada vez, e por isso as medidas agregadas são as de uma fila atendida por ordem de chegada.

2.4 Utilização e condição de estabilidade

A intensidade de tráfego, ou utilização, é

$$\rho = \frac{\lambda}{\mu}. \quad (4)$$

Em uma fila M/M/1 estável, ρ é a fração do tempo em que o servidor está ocupado. Para que exista regime estacionário com médias finitas, é preciso que

$$\lambda < \mu \quad \Longleftrightarrow \quad \rho < 1. \quad (5)$$

Quanto mais ρ se aproxima de 1, menor a folga do servidor e maiores a população e o tempo de permanência. Para $\rho \ge 1$ não há distribuição estacionária. No caso crítico ($\rho = 1$), o sistema volta a ficar vazio de tempos em tempos, mas não se estabiliza; com $\rho > 1$, a população cresce sem limite. Nesses casos, uma simulação de duração finita ainda produz números, que dependem do horizonte e não são médias de equilíbrio (TRIVEDI, 2001).

2.5 Medidas de desempenho do M/M/1

Seja $N(t)$ o número de solicitações no sistema no instante t, incluindo a que está em atendimento. A média estacionária é $L = \mathrm{E}[N]$ e a média apenas na fila de espera é $L_q = \mathrm{E}[N_q]$. Da mesma forma, $W = \mathrm{E}[W]$ é o tempo médio total no sistema e $W_q = \mathrm{E}[W_q]$ o tempo médio de espera antes do atendimento. Para a fila M/M/1 estável:

$$L = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda}, \qquad L_q = \frac{\rho^2}{1-\rho}, \quad (6)$$

$$W = \frac{1}{\mu - \lambda}, \qquad W_q = \frac{\rho}{\mu - \lambda}. \quad (7)$$

As versões V3 e V4 estimam a ocupação, L e W. A estimativa de L é uma média no tempo; a de W é indireta e inclui permanências cortadas no fim da execução (Seção 3.4). A V4 também estima L_q, W_q e os percentis de W (Seção 3.6).

Na M/M/1 com atendimento por ordem de chegada, o tempo no sistema tem distribuição exponencial de taxa $\mu - \lambda$ (TRIVEDI, 2001). Assim, o percentil p desse tempo, isto é, o valor que uma fração p dos clientes não ultrapassa, é

$$w_p = \frac{-\ln(1-p)}{\mu - \lambda}. \quad (8)$$

A mediana ($p = 0{,}5$) vale $\ln 2 \approx 0{,}69$ vez a média, e o percentil 95 vale $\ln 20 \approx 3{,}00$ vezes a média.

2.6 Lei de Little

A lei demonstrada por John Little em 1961 relaciona o número médio de elementos em um sistema estável, a taxa com que eles passam pelo sistema e o tempo médio de permanência (LITTLE, 1961):

$$L = \lambda_{\mathrm{ef}} W, \qquad L_q = \lambda_{\mathrm{ef}} W_q, \quad (9)$$

em que λ_{ef} é a taxa efetiva de entrada. Sem perdas e em regime estável, $\lambda_{\mathrm{ef}} = \lambda$. Ou seja, o número médio de clientes presentes é igual ao número que chega por unidade de tempo vezes o tempo que cada um fica. A lei vale para qualquer distribuição. No simulador, $\mathrm{E}[N]$ e $\mathrm{E}[W]$ saem das mesmas áreas acumuladas, de modo que o resíduo de Little calculado pelo programa dá praticamente zero por construção (Seção 3.4). Por isso, a V4 também mede o tempo de cada cliente diretamente.

3 Análise do simulador em linguagem C

3.1 Visão geral

O arquivo `simulacao_v3.c` simula por eventos discretos uma fila com um servidor. O relógio salta direto para a próxima chegada ou saída, sem passos fixos, o que evita processar períodos em que nada muda (ROSS, 2006).

O programa recebe o tempo médio entre chegadas, o tempo médio de atendimento e a duração da simulação. Durante a execução, mantém o relógio, o número de solicitações no sistema e os instantes da próxima chegada e da próxima saída. No final, imprime ocupação, E[N], E[W] e o resíduo de Little. Três estruturas do tipo `Info` acumulam áreas no tempo: uma para $N(t)$ e duas para os totais acumulados de chegadas e de saídas. Assim, as médias temporais são obtidas sem guardar o histórico do sistema. A Tabela 1 relaciona as grandezas do modelo às variáveis do código.

Tabela 1 – Correspondência entre as grandezas do modelo e as variáveis da V3.

Grandeza	Variável ou acumulador
Relógio t	`tempo_decorrido`
População $N(t)$	`fila` e `en.numero_eventos`
Próxima chegada	`chegada_cliente`
Próxima saída	`saida_cliente`
Taxa λ	`intervalo_chegadas` (após a conversão)
Taxa μ	`media_atendimento` (após a conversão)
Chegadas $A(t)$	`ew_chegadas.numero_eventos`
Saídas $D(t)$	`ew_saidas.numero_eventos`
Área sob $N(t)$	`en.soma_areas`

Fonte: Elaboração própria, a partir do código fornecido.

3.2 Laço de eventos

A variável `fila` guarda a população total, incluindo quem está em atendimento. Zero significa servidor ocioso, um significa uma solicitação em atendimento e valores maiores indicam espera. Com o sistema vazio, o próximo evento só pode ser uma chegada; com o sistema ocupado, é o menor instante entre chegada e saída. Entre dois eventos, em t_{i-1} e t_i, o estado não muda, e o intervalo $t_i - t_{i-1}$ é usado para atualizar as áreas.

Em uma chegada, a população e o contador de chegadas aumentam e a próxima chegada é sorteada. Se o servidor estava ocioso, o atendimento começa na hora e a saída é agendada. Em uma saída, a população diminui e o contador de saídas aumenta; se ainda houver alguém, o próximo atendimento começa e uma nova saída é agendada. Cada iteração do laço, portanto, (i) escolhe o próximo evento, (ii) acumula as áreas até ele e (iii) processa o evento e agenda os seguintes.

Na V3, o evento escolhido é processado mesmo que ocorra depois do horizonte T. Na V4, o limite é verificado antes: se o próximo evento está depois de T, as áreas são fechadas em T e o laço termina.

3.3 Cálculo da ocupação e de E[N]

Na V3, `soma_atendimentos` soma a duração de cada atendimento no instante em que ele começa, e o total é dividido pelo tempo final. Assim, um atendimento que começa antes do horizonte e termina depois dele é contado inteiro, inclusive a parte fora da janela observada. A V4 corrige isso acumulando a área do indicador "servidor ocupado" apenas até T.

O número médio de solicitações é a área sob $N(t)$ dividida pelo tempo observado T_{obs}:

$$\widehat{\mathrm{E}[N]} = \frac{1}{T_{\text{obs}}} \sum_i N_{i-1}(t_i - t_{i-1}). \tag{10}$$

Apesar do nome, `en.numero_eventos` guarda a população atual. Ele aumenta nas chegadas e diminui nas saídas.

3.4 Cálculo de E[W] e resíduo de Little

O código não guarda os instantes de chegada e saída de cada solicitação, apenas os totais acumulados $A(t)$ e $D(t)$. Como o sistema começa vazio e não há perdas, $N(t) = A(t) - D(t)$, e portanto

$$\int_0^{T_{\text{obs}}} N(t)\,dt = \int_0^{T_{\text{obs}}} A(t)\,dt - \int_0^{T_{\text{obs}}} D(t)\,dt. \tag{11}$$

O programa divide essa diferença de áreas pelo número de chegadas. Se a_j e d_j são os instantes de chegada e saída da solicitação j, o resultado é

$$\widehat{\mathrm{E}[W]} = \frac{\sum_{j:\, a_j \le T_{\text{obs}}} \left[\min(d_j, T_{\text{obs}}) - a_j\right]}{A(T_{\text{obs}})}. \tag{12}$$

Ou seja, quem ainda está no sistema no final contribui só com o tempo que ficou até T_{obs}. Isso acontece nas duas versões.

Um exemplo pequeno mostra o que acontece com o resíduo de Little. Com $T_{\text{obs}} = 4$, considere um cliente que chega em 0 e sai em 3 e outro que chega em 1 e sairia em 5. A área sob $N(t)$ é $3 + 3 = 6$, porque o segundo cliente é cortado em 4. Daí $\widehat{\mathrm{E}[W]} = 6/2 = 3$, $\widehat{\mathrm{E}[N]} = 6/4 = 1{,}5$ e $\widehat{\lambda} = 2/4 = 0{,}5$, e $\widehat{\lambda}\widehat{\mathrm{E}[W]} = 1{,}5$ repete $\widehat{\mathrm{E}[N]}$. O mesmo vale para qualquer trajetória: como $\widehat{\mathrm{E}[W]} = \int N\,dt/A(T_{\text{obs}})$, $\widehat{\mathrm{E}[N]} = \int N\,dt/T_{\text{obs}}$ e $\widehat{\lambda} = A(T_{\text{obs}})/T_{\text{obs}}$, o resíduo $\widehat{\mathrm{E}[N]} - \widehat{\lambda}\widehat{\mathrm{E}[W]}$ é zero por construção, a menos de arredondamento. Ele mostra que os acumuladores estão consistentes e nada diz sobre a Lei de Little. Para testá-la, a V4 mede também o tempo de cada cliente (Seção 3.6).

3.5 Versões utilizadas no experimento

O arquivo original ficou intacto, mas não serve para rodar em lote. Ele imprime uma mensagem por evento e usa `time(NULL)` como semente, então execuções iniciadas no mesmo segundo repetem os mesmos sorteios. Repetições assim estreitariam o IC sem trazer informação nova. Por isso criamos a cópia `simulacao_v3_testes.c`, que recebe a semente pela entrada, valida as entradas e imprime só as estatísticas. A lógica dos eventos e os estimadores são os do original, inclusive o processamento além do horizonte e a soma antecipada dos atendimentos. Nos resultados, "V3" se refere a essa cópia.

A `simulacao_v4.c` mantém o mesmo modelo e as mesmas medidas. Duas de suas mudanças afetam os resultados: o encerramento exatamente em T, com as áreas fechadas nesse instante, e a contagem da ocupação apenas dentro da janela $[0, T]$. As outras duas, validação das entradas e proteção contra divisão por zero quando não há chegadas, não alteram nenhum número das execuções que fizemos. Como a cópia de testes da V3 também recebe a semente, rodamos as duas versões com os mesmos números aleatórios, e a diferença entre elas mede o efeito das duas correções.

O script `experimentos_mm1.py` compila e executa os programas em C, organiza as saídas em CSV, calcula médias e intervalos de confiança e gera os gráficos. A dinâmica da fila fica toda nos programas em C.

3.6 Extensões da V4

$\mathrm{E}[N_q]$ e $\mathrm{E}[W_q]$ seguem o mesmo padrão de áreas do código original. A quantidade na fila de espera é $N_q(t) = \max(N(t) - 1, 0)$; sua área, dividida pelo tempo observado, dá $\widehat{\mathrm{E}[N_q]}$, e dividida pelo número de chegadas dá $\widehat{\mathrm{E}[W_q]}$. Como no caso de $\mathrm{E}[W]$, a relação $\widehat{\mathrm{E}[N_q]} = \widehat{\lambda}\widehat{\mathrm{E}[W_q]}$ vale por construção. Acrescentamos também o comprimento máximo de $N(t)$ durante a observação.

Para medir o tempo de cada cliente, a V4 guarda os instantes de chegada numa lista, em ordem. Como o atendimento é por ordem de chegada, quem sai é sempre o primeiro da lista, e seu tempo no sistema é o instante da saída menos o da chegada. Só entram nessa conta os clientes que chegaram e saíram dentro da janela observada. No final, o programa calcula a média desses tempos, que chamamos de W direto, e ordena a lista para obter a mediana (P50) e o percentil 95 (P95). Como esse W não vem das áreas, a relação $\widehat{\mathrm{E}[N]} = \widehat{\lambda}\widehat{W}$ deixa de valer por construção e passa a ser um teste.

A V4 também aceita um quinto valor de entrada, opcional: o tempo de aquecimento T_a. Quando a simulação passa de T_a, todas as áreas e contadores são zerados e a coleta recomeça, de modo que as medidas descrevem só a janela $[T_a, T]$. As solicitações já presentes nesse instante são contadas como chegadas da janela no acumulador de chegadas, para que a diferença entre as áreas de chegadas e saídas continue igual a $N(t)$, mas ficam fora do denominador de $\widehat{\mathrm{E}[W]}$ e $\widehat{\lambda}$. Sem o quinto valor, $T_a = 0$ e a coleta começa no instante zero, como nas execuções do experimento principal.

3.7 Limitações

No experimento principal, as execuções começam com o sistema vazio e não descartam aquecimento; avaliamos o efeito do descarte em um experimento separado (Seções 4.3 e 5.9). Na V3, o tempo de permanência só é obtido de forma indireta, com as permanências cortadas no fim; a V4 contorna isso medindo o tempo de cada cliente.

Mantivemos o gerador `rand()` para preservar o código da disciplina. Ele produz inteiros em um conjunto finito: na glibc 2.43 que usamos, `RAND_MAX` vale $2^{31} - 1$, cerca de 2,1 bilhões de valores, de modo que U assume valores em uma grade. Não testamos a aderência das amostras à exponencial. A concordância com a teoria nos cenários estáveis não aponta problema causado pelo gerador, mas também não o descarta.

4 Metodologia

4.1 Cenários e valores teóricos

Fixamos a taxa de atendimento em $\mu = 1$ solicitação por segundo e controlamos a carga pela taxa de chegada, de modo que $\lambda = \rho$. Escolhemos os cenários para ir de uma carga baixa até a saturação, com mais pontos perto de $\rho = 1$, onde as medidas mudam mais rápido. Antes de simular, calculamos os valores teóricos de cada cenário estável pelas Equações 6 e 7 (Tabela 2). C7 ($\rho = 1$) e C8 ($\rho = 1{,}1$) não têm regime estacionário e entraram para observarmos o que acontece quando a condição de estabilidade é violada.

Tabela 2 – Cenários avaliados e valores teóricos calculados antes da simulação ($\mu = 1$, $\lambda = \rho$).

Cenário	ρ	$\mathrm{E}[N]$	$\mathrm{E}[W]$	$\mathrm{E}[N_q]$	$\mathrm{E}[W_q]$
C1	0,25	0,333	1,333	0,083	0,333
C2	0,50	1,000	2,000	0,500	1,000
C3	0,75	3,000	4,000	2,250	3,000
C4	0,90	9,000	10,000	8,100	9,000
C5	0,95	19,000	20,000	18,050	19,000
C6	0,99	99,000	100,000	98,010	99,000
C7	1,00	–	–	–	–
C8	1,10	–	–	–	–

Fonte: Elaboração própria.

A tabela mostra por que a região perto de $\rho = 1$ é a mais delicada. Como $\mathrm{E}[W] = 1/(\mu - \lambda)$, o tempo no sistema depende da folga do servidor, $1 - \rho$. Quando a folga cai de 0,10 ($\rho = 0{,}90$) para 0,01 ($\rho = 0{,}99$),

a carga sobe só 10%, e E[W] passa de 10 para 100 segundos.

4.2 Horizontes, repetições e sementes

Uma simulação de duração finita só se aproxima da média de longo prazo, e a aproximação melhora com a duração. Para observar isso, rodamos cada cenário com cinco horizontes, de $T = 10^2$ a $T = 10^6$ segundos. O horizonte de 10^6 está aí por causa de C6, cujo IC de E[N] ainda tem semiamplitude de 20,6% da média em $T = 10^5$. Isso era esperado. Morse mostrou que o tempo de relaxação da fila, que é o tempo que ela leva para "esquecer" o estado inicial, cresce com $(1 - \rho)^{-2}$ (MORSE, 1955). De $\rho = 0{,}90$ para $\rho = 0{,}99$, esse fator passa de 100 para 10.000.

Cada combinação de cenário e horizonte foi repetida 30 vezes, com sementes diferentes, e tratamos as repetições como independentes. Com isso, as 30 médias permitem estimar a incerteza por meio de um intervalo de confiança. Foram $8 \times 5 \times 30 = 1.200$ execuções por versão.

As duas versões receberam exatamente as mesmas sementes. Como V3 e V4 sorteiam os números aleatórios na mesma ordem, cada par de execuções percorre a mesma trajetória até o horizonte, e as diferenças vêm só das correções da V4. Já horizontes diferentes usam sementes diferentes, então os pontos de um gráfico de convergência não são prefixos de uma mesma trajetória. Todas essas execuções começaram com o sistema vazio.

4.3 Experimento de aquecimento

Como o sistema começa vazio, os primeiros instantes de cada execução não representam o regime estacionário. Uma forma de contornar isso é descartar um período inicial, o aquecimento (do inglês *warm-up*), e só depois começar a medir. Para avaliar o efeito, rodamos a V4 em C4, C5 e C6 com uma janela de medição fixa de 10^4 segundos, precedida de aquecimentos de 0, 10^3, 10^4 e 10^5 segundos. Escolhemos a janela curta de propósito, porque é nela que o viés do início vazio aparece com mais força.

Os outros dois parâmetros também saem do experimento principal. Ficamos com C4, C5 e C6 porque, em $T = 10^4$, o erro de E[N] neles foi de 5,0%, 6,0% e 53%, contra no máximo 2,1% nos demais cenários estáveis. E usamos 200 repetições porque, com 30, o IC de E[N] em C6 nesse horizonte tem semiamplitude de 21% da média, larga demais para distinguir aquecimentos próximos; com 200, ela cai para 8,2%.

4.4 Tratamento estatístico

Para cada conjunto de R repetições, calculamos a média e o intervalo de confiança (IC) de 95% pela distribuição t de Student:

$$\bar{x} \pm t_{0{,}975;R-1}\frac{s}{\sqrt{R}}. \tag{13}$$

O IC indica a faixa em que, com 95% de confiança, está a média que o simulador produziria com infinitas repetições. Se o valor teórico cai dentro dele, a diferença pode ser explicada pela aleatoriedade. Se cai fora, pode ser acaso (esperamos 1 caso em 20) ou erro sistemático. A distância até a teoria foi medida pelo erro relativo:

$$\text{Erro (\%)} = 100\left|\frac{\text{simulado} - \text{teórico}}{\text{teórico}}\right|. \tag{14}$$

Como E[N] vai de 0,33 a 99 entre os cenários, algumas figuras mostram a média dividida pelo valor teórico, e 1 significa concordância exata. As figuras mostram só E[N], porque o simulador calcula $\widehat{\mathrm{E}[W]} = \widehat{\mathrm{E}[N]}/\widehat{\lambda}$ (Seção 3.4) e os erros das duas medidas andam juntos: em $T = 10^6$, diferem no máximo 0,03 ponto percentual. E[W] aparece nas tabelas.

Na comparação entre versões, calculamos a diferença V3−V4 em cada par de execuções com a mesma semente e aplicamos o IC da Equação 13 a essas diferenças. Um IC que contém zero indica que não detectamos diferença entre as versões.

4.5 Ambiente e reprodução

Rodamos tudo em um computador com processador Intel Core i5-12450HX e cerca de 15 GB de memória, com Ubuntu 26.04 e glibc 2.43. Os simuladores foram compilados com GCC 15.2.0 (`-O2 -std=c11 -Wall -Wextra -lm`). O script `experimentos_mm1.py` (Python 3.14.4, Matplotlib 3.10.7 e SciPy 1.16.3) executa todas as combinações, salva os CSVs e gera as figuras. Repetimos o lote completo, com as 2.400 execuções do experimento principal e as 2.400 do aquecimento, e os CSVs saíram idênticos, byte a byte. Como `rand()` depende da biblioteca C, quem rodar com outra biblioteca pode obter números diferentes.

Os códigos, os dados de cada execução e as instruções de reprodução estão em `https://github.com/JeannVictor/Trabalho_1_Analise_Desempenho`. As figuras deste artigo vêm da V4, exceto as que comparam as versões; as equivalentes da V3 ficam na pasta `codigo/dados/figuras`.

5 Resultados e discussão

5.1 Teoria e simulação

Começamos verificando se o simulador reproduz a teoria quando tem tempo suficiente. A Tabela 3 compara os valores teóricos com as médias de $T = 10^6$. Nesse horizonte, as médias de V3 e V4 coincidem até a quarta casa decimal (Seção 5.6), e por isso a tabela traz uma só média.

Tabela 3 – Resultados nos cenários estáveis para $T = 10^6$ (30 repetições).

Cenário	Medida	Teórico	Média simulada (V3 = V4)	IC de 95% (V4)	Erro (%)
C1	Ocupação	0,2500	0,2499	[0,2497; 0,2502]	0,023
C1	E[N]	0,3333	0,3333	[0,3328; 0,3337]	0,022
C1	E[W]	1,3333	1,3333	[1,3315; 1,3350]	0,006
C2	Ocupação	0,5000	0,4997	[0,4994; 0,5000]	0,055
C2	E[N]	1,0000	0,9986	[0,9968; 1,0004]	0,139
C2	E[W]	2,0000	1,9977	[1,9944; 2,0009]	0,117
C3	Ocupação	0,7500	0,7499	[0,7496; 0,7503]	0,008
C3	E[N]	3,0000	3,0017	[2,9922; 3,0112]	0,057
C3	E[W]	4,0000	4,0034	[3,9910; 4,0158]	0,084
C4	Ocupação	0,9000	0,9000	[0,8995; 0,9004]	0,005
C4	E[N]	9,0000	9,0215	[8,9656; 9,0775]	0,239
C4	E[W]	10,0000	10,0263	[9,9657; 10,0868]	0,263
C5	Ocupação	0,9500	0,9492	[0,9486; 0,9498]	0,084
C5	E[N]	19,0000	18,6843	[18,3500; 19,0185]	1,662
C5	E[W]	20,0000	19,6735	[19,3260; 20,0210]	1,633
C6	Ocupação	0,9900	0,9899	[0,9894; 0,9905]	0,008
C6	E[N]	99,0000	97,8988	[91,9794; 103,8181]	1,112
C6	E[W]	100,0000	98,8953	[92,9277; 104,8630]	1,105

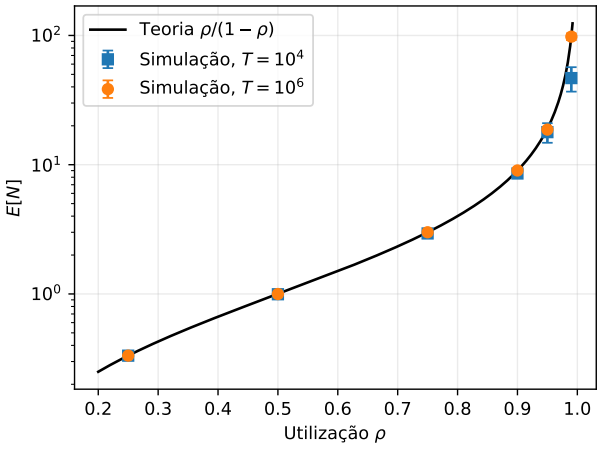
Fonte: Elaboração própria.

Consideramos que o simulador reproduziu a teoria nos seis cenários estáveis, pois o valor teórico de E[N] e E[W] ficou dentro do IC em todos eles. A ocupação teve erro de no máximo 0,084% (C5). Em E[N] e E[W], o erro ficou abaixo de 0,3% até $\rho = 0{,}90$ e entre 1,1% e 1,7% em C5 e C6. O único IC sem a teoria foi o da ocupação de C5, [0,9486; 0,9498] contra 0,95; com 18 intervalos de 95%, esperamos $18 \times 0{,}05 = 0{,}9$ fora por acaso.

Interpretamos o erro maior perto da saturação da seguinte forma: nessa região, a fila passa longos períodos acumulada ou vazia, e uma execução contém poucos desses períodos. As médias variam mais de uma execução para outra e o IC alarga. Foi o que nos levou a $T = 10^6$. Com $T = 10^5$, o IC de E[N] em C4, [8,59; 8,99], não continha 9, e o de C6 tinha semiamplitude de 20,6% da média, contra 6,0% em $T = 10^6$. Como a incerteza de uma média temporal cai com $1/\sqrt{T}$, esperávamos uma redução de $\sqrt{10} \approx 3{,}2$ vezes, e medimos entre 3,2 e 3,7 vezes em cinco cenários. Em C5 ela foi de só 1,9 vez, e não sabemos explicar essa diferença.

Na Figura 1, a mesma comparação aparece em forma de curva. Com $T = 10^6$, todos os pontos caem sobre a curva teórica; com $T = 10^4$, o ponto de $\rho = 0{,}99$ fica bem abaixo dela (46,8 contra 99), efeito que discutimos a seguir.

Figura 1 – E[N] teórico (curva) e médias simuladas pela V4 com IC de 95%, para $T = 10^4$ e $T = 10^6$; escala logarítmica.



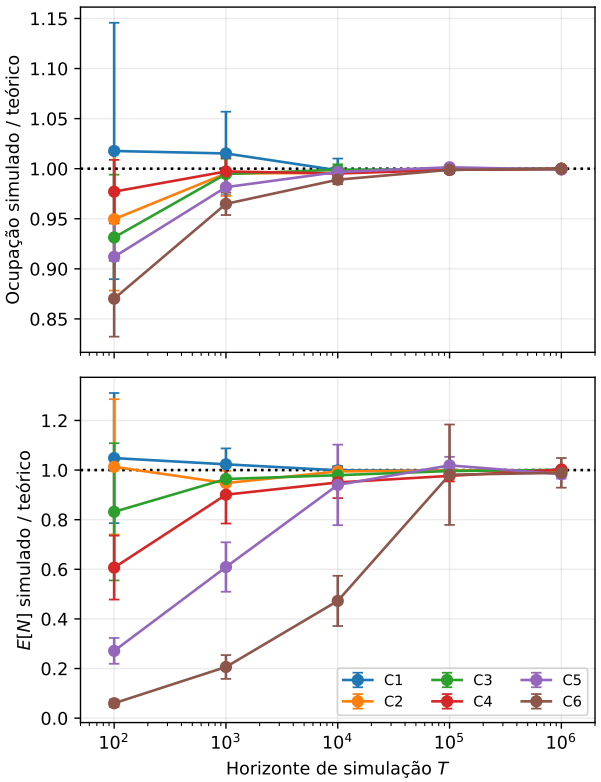
Fonte: Elaboração própria.

5.2 Influência do horizonte de simulação

A Figura 2 mostra como as estimativas mudam com o horizonte. Em C1 e C2, E[N] oscila em torno da teoria desde os horizontes curtos, entre 0,95 e 1,05 vez o valor teórico. Nas cargas altas, os horizontes curtos ficam abaixo da teoria, e o efeito piora com ρ: em $T = 10^2$, E[N] ficou em 61% do valor teórico em C4, 27% em C5 e 6% em C6.

Atribuímos isso ao início vazio. Em C6, a fila típica do regime estacionário tem 99 solicitações, e a simulação começa com zero. Com o servidor ocupado, sai em média só 0,01 solicitação por segundo a mais do que entra, então a fila quase não tem tendência de subir nem de descer. Ela chega ao nível típico por flutuações aleatórias, o que demora, e todo esse período de enchimento entra na média. Em C6, a estimativa estava em 47% da teoria em $T = 10^4$ e chegou a 98%

Figura 2 – Ocupação e E[N] da V4 divididos pelo valor teórico, em função do horizonte, com ICs de 95%.



Fonte: Elaboração própria.

em $T = 10^5$.

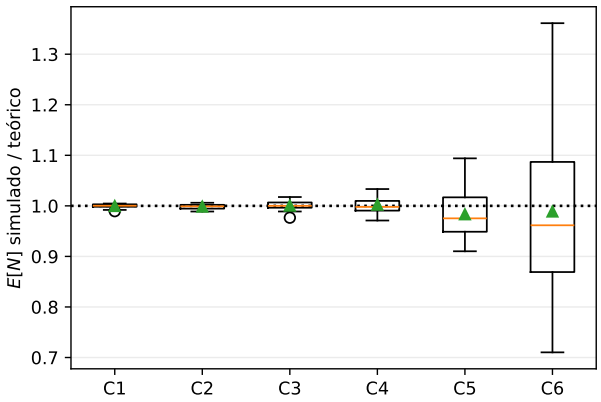
O desvio apareceu nos dois experimentos que medem essa configuração, com sementes diferentes. Sem aquecimento e com janela de 10^4 segundos, C6 deu 47% com 30 repetições, IC [0,37; 0,57], e 50% com 200 repetições, IC [0,46; 0,54]. O IC estreitou e continuou longe de 1, então aumentar as repetições não corrige esse erro. A duração necessária, portanto, depende da carga: em $T = 10^4$, o erro de E[N] foi de 2,1% em C3 e de 53% em C6.

5.3 Variabilidade entre repetições

O IC descreve a incerteza da média de 30 execuções. Para saber quanto uma execução isolada pode errar, a Figura 3 mostra as 30 estimativas de E[N] com $T = 10^6$.

De C1 a C4, todas as execuções ficaram a menos de 4% da teoria. Em C5, a variação chegou a cerca de 10% e, em C6, as estimativas foram de 0,71 a 1,36 vez o valor teórico. Ou seja, mesmo com um milhão de segundos simulados, cerca de 990 mil chegadas, uma única execução com $\rho = 0{,}99$ pode errar E[N] em mais de 30%. Nesse cenário, uma execução só não basta.

Figura 3 – Estimativas de E[N] divididas pelo valor teórico nas 30 execuções (V4, $T = 10^6$). A caixa vai do 1º ao 3º quartil, a linha interna é a mediana e o triângulo é a média.

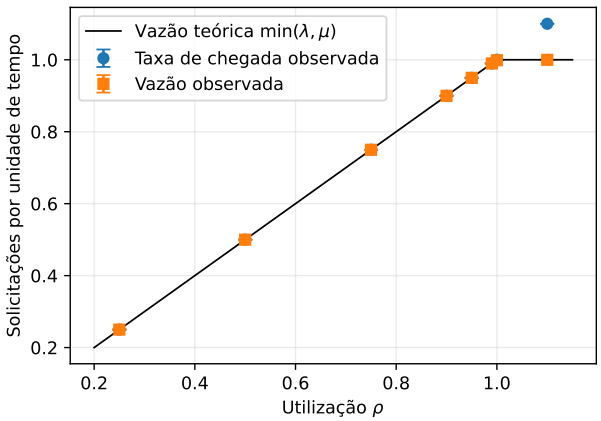


Fonte: Elaboração própria.

5.4 Vazão e verificações de consistência

Um servidor não atende mais do que μ solicitações por segundo, então a vazão de longo prazo é $\min(\lambda, \mu)$. Na Figura 4, a vazão acompanha λ até $\rho = 1$ e depois fica presa em 1. Em C8, com λ configurado em 1,10, chegaram em média 1,1001 solicitações por segundo e saíram 0,9998; a diferença, de cerca de 0,10, se acumula na fila.

Figura 4 – Taxa de chegada observada, vazão da V4 e vazão teórica $\min(\lambda, \mu)$ para $T = 10^6$.



Fonte: Elaboração própria.

Como as execuções começam vazias, o número de solicitações no final deve ser exatamente o número de chegadas menos o de saídas:

$$(\widehat{\lambda} - \widehat{v})\, T_{\text{obs}} = A(T_{\text{obs}}) - D(T_{\text{obs}}) = N(T_{\text{obs}}), \quad (15)$$

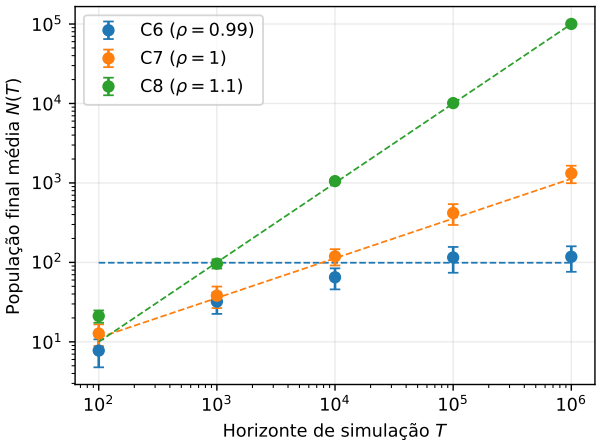
em que $\widehat{v}$ é a vazão observada. Conferimos a igualdade nas 2.400 execuções. A maior diferença ficou abaixo de 10^{-6} solicitação, compatível com o arredondamento, já que as taxas são impressas com 12 casas decimais

e multiplicadas por até 10^6. Logo, o código não criou nem perdeu solicitações. O resíduo de Little calculado pelas áreas ficou abaixo de 6×10^{-8}, mas, como vimos na Seção 3.4, ele é nulo por construção e não serve de evidência. A verificação independente da lei está na Seção 5.8.

5.5 Cenários crítico e sobrecarregado

A Figura 5 mostra o que acontece com a população final quando o horizonte cresce, comparando C6, que é estável, com C7 e C8, que não são.

Figura 5 – População final média da V4 em função do horizonte, com ICs de 95%. Tracejado: $\rho/(1-\rho)$ para C6, $\sqrt{4T/\pi}$ para C7 e $(\lambda-\mu)T$ para C8.



Fonte: Elaboração própria.

Os três cenários se comportam de maneiras diferentes. Em C6, a população para de crescer perto de $\mathrm{E}[N] = 99$: em $T = 10^5$ e $T = 10^6$, a média ficou em 115 e 118, com ICs ([74; 157] e [76; 159]) que contêm 99. Em C8, chegam 0,1 solicitação por segundo a mais do que o servidor atende, e o excesso se acumula. Como o servidor fica quase sempre ocupado, até T chegam cerca de λT solicitações e saem cerca de μT; essa é a aproximação de fluido, que vem da lei dos grandes números (WHITT, 2002). A previsão é $(\lambda-\mu)T$, e em $T = 10^6$ medimos 100.250 contra 100.000, diferença de 0,25%. A reta só falha em $T = 10^2$ (21 contra 10), o que interpretamos como efeito das flutuações, que nessa escala ainda pesam mais que o acúmulo.

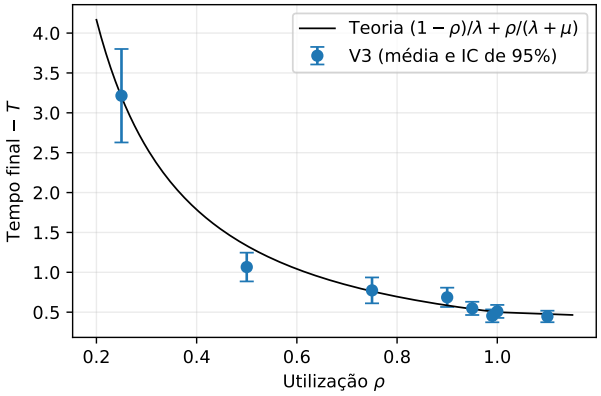
Em C7, entra em média o mesmo número de solicitações que sai, então não há acúmulo sistemático. Aproximamos a população por um passeio aleatório refletido em zero, o que basta para o nosso propósito: ela sobe e desce ao acaso e nada a puxa de volta. Para T grande, esse passeio se comporta como um movimento browniano refletido, que tem a mesma distribuição do módulo de uma normal de média zero (HARRISON, 1985). Com variância $\lambda+\mu = 2$ por unidade de tempo, a média do módulo é $\sqrt{2 \cdot 2T/\pi} = \sqrt{4T/\pi} \approx 1{,}13\sqrt{T}$. A razão entre a população final e $\sqrt{T}$ ficou entre 1,19 e 1,32, sempre acima de 1,13, mas a previsão ficou dentro do IC nos cinco horizontes. Em $T = 10^6$, são 1.128 previstos contra 1.319 medidos, com IC [992; 1.647]. Com 30 repetições, não dá para dizer se essa diferença é só acaso.

Em C7 e C8, a população não se estabiliza, então as médias de $\mathrm{E}[N]$ e $\mathrm{E}[W]$ dependem do horizonte. Em C8, por exemplo, $\mathrm{E}[N]$ passou de 5.075 em $T = 10^5$ para 50.101 em $T = 10^6$.

5.6 Comparação entre V3 e V4

A V3 só encerra depois de processar o primeiro evento posterior ao horizonte, então seu tempo final sempre passa de T. A falta de memória da exponencial permite prever esse excesso. Se o servidor está ocioso em T, o próximo evento só pode ser uma chegada, que demora em média $1/\lambda$. Se está ocupado, pode ser uma chegada ou uma saída, e demora em média $1/(\lambda+\mu)$. Ponderando pela ocupação, o excesso médio é $(1-\rho)/\lambda + \rho/(\lambda+\mu)$; com $\rho \geq 1$, o servidor fica sempre ocupado e sobra $1/(\lambda+\mu)$. Em C1, isso dá $0{,}75/0{,}25 + 0{,}25/1{,}25 = 3{,}2$ s. Como o valor não depende de T, reunimos os cinco horizontes na Figura 6, com 150 execuções por cenário.

Figura 6 – Excesso médio do tempo final da V3 sobre o horizonte, reunindo os cinco horizontes, e previsão teórica.

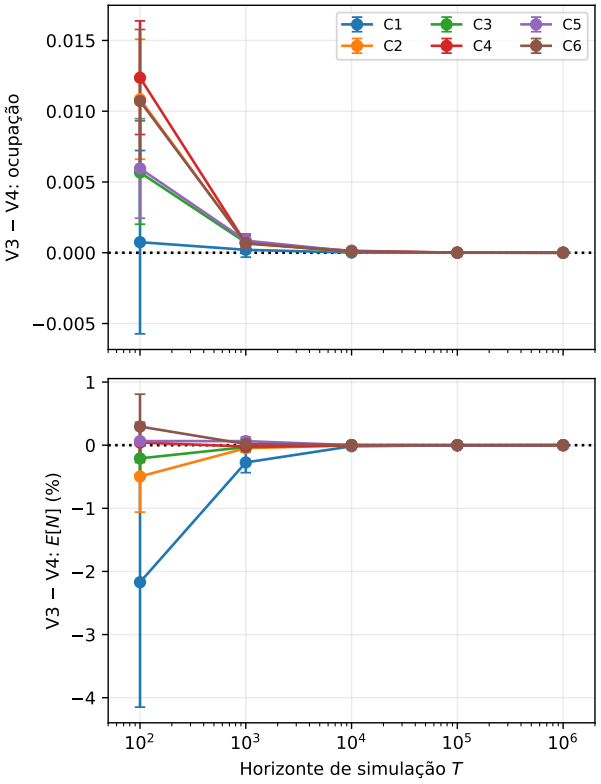


Fonte: Elaboração própria.

Medimos 3,21 s em C1, contra 3,20 s previstos, e entre 0,45 e 0,69 s de C4 a C8, contra 0,48 a 0,58 s. O ponto que mais se afastou foi C2, com 1,07 s contra 1,33 s e IC [0,89; 1,25]. Foi o único dos oito intervalos sem a previsão; esperávamos $8 \times 0{,}05 = 0{,}4$ fora por acaso, e os dados não permitem dizer se é isso. Como o excesso tem tamanho fixo, seu peso cai com o horizonte: em C1, foi de 3,6% de T em $T = 10^2$ e de 0,0004% em $T = 10^6$.

A Figura 7 mostra o efeito sobre as medidas. Em $T = 10^2$, a ocupação média da V3 foi maior que a da V4 em todos os cenários, em até 0,012, porque a V3 soma a duração de cada atendimento no momento em

Figura 7 – Diferença pareada V3−V4 nos cenários estáveis, com ICs de 95%: absoluta para a ocupação e relativa para E[N].



Fonte: Elaboração própria.

que ele começa, inclusive a parte que termina depois de T. Em E[N], as diferenças não têm sinal definido e ficaram, em média, em 1,2% em $T = 10^2$. A partir de $T = 10^4$, ficam abaixo de 0,03%.

Concluímos que a lógica central da V3 está correta, pois as duas versões percorrem a mesma trajetória até T e suas médias em $T = 10^6$ coincidem até a quarta casa. Seus problemas estão na fronteira da janela de observação e só pesam nas execuções curtas. Preferimos a V4 por medir exatamente o intervalo $[0, T]$.

5.7 Medidas adicionais da V4

Este subitem e os dois seguintes tratam do que só a V4 mede. A Tabela 4 traz a fila de espera e o comprimento máximo da fila.

Os erros de E[N_q] e E[W_q] ficaram próximos aos de E[N] (em C5, 1,745% e 1,716%, contra 1,662%), e a teoria ficou dentro do IC nos seis cenários. Era o esperado, já que $N(t) = N_q(t) + 1$ sempre que o servidor está ocupado e a ocupação tem erro abaixo de 0,1%.

O comprimento máximo da fila cresce com a duração da simulação. Em C3, foi de 23,0 em $T = 10^4$ para 38,7 em $T = 10^6$; em C6, de 130,4 para 533,8. Quanto mais longa a observação, maior a chance de ocorrer um congestionamento raro. O máximo também fica muito acima da média: em C3, onde E[N] = 3, a fila chegou em média a 39 solicitações, 13 vezes a média. Então o máximo só faz sentido junto com a duração da observação, e dimensionar um sistema pela média subestimaria os seus picos.

5.8 Lei de Little com tempos individuais e percentis

Até aqui, não pudemos testar a Lei de Little, porque o resíduo calculado a partir das áreas é zero de qualquer forma. Com o tempo de cada cliente medido diretamente, $\widehat{\mathrm{E}[N]}$ continua vindo da área sob $N(t)$, e W passa a ser a média dos tempos que cada cliente realmente passou no sistema. Se as duas medidas estiverem corretas, $\widehat{\lambda}\,\widehat{W}$ deve reproduzir $\widehat{\mathrm{E}[N]}$. A Tabela 5 mostra o resultado.

Em $T = 10^6$, a diferença entre $\widehat{\mathrm{E}[N]}$ e $\widehat{\lambda}\,\widehat{W}$ ficou abaixo de 0,002% nos seis cenários estáveis, o que confirma a lei com uma medida que não depende das áreas de chegadas e saídas. Em $T = 10^2$ ela chegava a 2%. Essa diferença vem da borda da janela: os clientes que ainda estão no sistema no fim da execução entram na área sob $N(t)$, mas não na média dos tempos individuais, e numa janela curta eles pesam mais. O W direto também ficou praticamente igual ao indireto em $T = 10^6$ (diferença máxima de 0,001 s em 98,9 s, em C6), então o corte das permanências no fim da execução (Seção 3.4) não afetou os horizontes longos.

Nos percentis, os valores simulados seguiram a exponencial prevista pela Equação 8. O P50 ficou a menos de 2% da teoria e o P95 a menos de 3%, com a teoria dentro do IC em 11 dos 12 casos. A exceção foi o P50 de C5, com 13,59 s contra 13,86 s e IC [13,41; 13,77]. C5 é o mesmo cenário em que a ocupação ficou fora do IC; as duas medidas vêm das mesmas 30 execuções e podem ter a mesma origem. Em C4, o tempo médio no sistema é de 10 s, metade dos clientes fica menos de 7 s e um em cada vinte fica mais de 30 s: o P95 previsto é $\ln 20/0{,}1 = 29{,}96$ s, e medimos 30,13 s, diferença de 0,6%. A média sozinha não mostra esses 5%.

5.9 Efeito do aquecimento

Na Seção 5.2, atribuímos ao início vazio o fato de os horizontes curtos subestimarem a teoria. Se essa é a causa, descartar o período inicial deve resolver o problema. A Figura 8 mostra o teste.

Em C6, sem aquecimento, a janela de 10^4 segundos estimou 50% do valor teórico. Descartando 10^3, 10^4 e 10^5 segundos, a estimativa subiu para 63%, 80% e 97%, e só no último caso o IC, [0,85; 1,09], passou a conter a teoria. Nesse caso, cada execução simulou $1{,}1 \times 10^5$ segundos para aproveitar 10^4. Em C5, a estimativa sem aquecimento ficou em 94%, com IC [0,89; 0,98], e passou a conter a teoria com qualquer um dos descartes. Em C4, ela já continha a teoria sem aquecimento (99%). O único IC fora nesse cenário foi o

Tabela 4 – Medidas adicionais da V4: fila de espera para $T = 10^6$ e comprimento máximo médio da fila para dois horizontes (30 repetições).

	$\mathrm{E}[N_q]$			$\mathrm{E}[W_q]$			Fila máxima	
Cenário	Teórico	Simulado	Erro (%)	Teórico	Simulado	Erro (%)	$T = 10^4$	$T = 10^6$
C1	0,0833	0,0833	0,018	0,3333	0,3333	0,002	6,3	9,5
C2	0,5000	0,4989	0,223	1,0000	0,9980	0,201	11,8	18,4
C3	2,2500	2,2518	0,079	3,0000	3,0032	0,106	23,0	38,7
C4	8,1000	8,1216	0,267	9,0000	9,0261	0,290	47,0	95,6
C5	18,0500	17,7351	1,745	19,0000	18,6740	1,716	72,9	159,1
C6	98,0100	96,9088	1,124	99,0000	97,8953	1,116	130,4	533,8

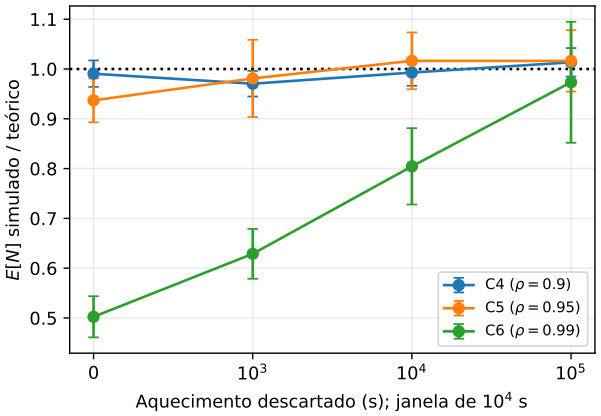
Fonte: Elaboração própria.

Tabela 5 – Tempo de permanência medido cliente a cliente pela V4 para $T = 10^6$ (30 repetições). "Dif. de Little" é $100\,(\widehat{\mathrm{E}[N]} - \widehat{\lambda W})/\widehat{\mathrm{E}[N]}$, com W direto.

	$\mathrm{E}[W]$				P50 de W		P95 de W	
Cenário	Teórico	Indireto	Direto	Dif. de Little (%)	Teórico	Simulado	Teórico	Simulado
C1	1,3333	1,3333	1,3333	0,0001	0,92	0,92	3,99	4,00
C2	2,0000	1,9977	1,9977	−0,0001	1,39	1,39	5,99	5,98
C3	4,0000	4,0034	4,0034	0,0000	2,77	2,77	11,98	12,00
C4	10,0000	10,0263	10,0263	−0,0001	6,93	6,93	29,96	30,13
C5	20,0000	19,6735	19,6734	0,0002	13,86	13,59	59,91	59,26
C6	100,0000	98,8953	98,8943	0,0015	69,31	68,75	299,57	308,35

Fonte: Elaboração própria.

Figura 8 – $\mathrm{E}[N]$ da V4 dividido pelo valor teórico numa janela de 10^4 s, em função do aquecimento descartado (200 repetições, ICs de 95%).



Fonte: Elaboração própria.

do aquecimento de 10^3 segundos (97%), que tratamos como acaso, porque os descartes maiores voltaram a conter a teoria.

O descarte aproximou a estimativa da teoria e alargou o IC: em C6, a semiamplitude passou de 8,2% para 12,5% da média. Nossa leitura é que a janela deixa de começar sempre do mesmo estado (vazio) e passa a começar de estados variados, típicos do regime estacionário. Nas cargas muito altas, portanto, o aquecimento precisa vir junto com uma janela de medição longa.

6 Considerações finais

Queríamos saber em que condições o simulador da disciplina reproduz o modelo M/M/1. Nos seis cenários estáveis, ele reproduziu, desde que a simulação dure o suficiente: com $T = 10^6$, os erros de $\mathrm{E}[N]$ e $\mathrm{E}[W]$ ficaram abaixo de 0,3% até $\rho = 0{,}90$ e abaixo de 2% em $\rho = 0{,}95$ e 0,99, com a teoria dentro do intervalo de confiança em todos os casos. A vazão seguiu $\min(\lambda, \mu)$, e a conservação do fluxo valeu nas 2.400 execuções.

Essa duração depende muito da carga. Como a simulação começa com o sistema vazio, o enchimento da fila puxa as médias para baixo: com $T = 10^4$, o erro de $\mathrm{E}[N]$ foi de 2,1% em $\rho = 0{,}75$ e de 53% em $\rho = 0{,}99$. Descartar 10^5 segundos de aquecimento levou a estimativa de $\rho = 0{,}99$ de 50% para 97% da teoria, com um IC mais largo (de 8,2% para 12,5% da média). Para quem for simular perto de $\rho = 1$, sugerimos não confiar em uma execução só e conferir se a estimativa ainda muda quando o horizonte aumenta dez vezes. Em $\rho = 0{,}99$, ela foi de 47% em $T = 10^4$ para 98% em $T = 10^5$ e 99% em $T = 10^6$.

Quando $\rho \geq 1$, a fila não se estabilizou. No caso crítico, a população cresceu com a raiz do tempo (de 1,19 a 1,32 vez $\sqrt{T}$, contra 1,13 previstos, com a previ-

são dentro do IC nos cinco horizontes). No sobrecarregado, cresceu linearmente (100.250 contra 100.000 em $T = 10^6$), com a vazão presa em 0,9998. Nesses casos, as médias simuladas só descrevem a janela observada e não podem ser comparadas com as fórmulas de regime estacionário.

A comparação entre as versões mostrou que a lógica da V3 está correta. O tempo final que passa do horizonte e a ocupação contada antes da hora só alteram os resultados nas execuções curtas: a partir de $T = 10^4$, a diferença em E[N] fica abaixo de 0,03%. A V4 corrige essas falhas e mede o que as médias não mostram. A fila de espera seguiu a teoria, a Lei de Little se confirmou com tempos medidos cliente a cliente (diferença abaixo de 0,002%), e os percentis e a fila máxima deram o tamanho dos piores casos. Em C4, com média de 10 s, um em cada vinte clientes fica mais de 30 s.

Em $T = 10^6$, a maior fonte de erro que restou é a variação entre execuções: em C6, ela deixa o IC de E[N] com semiamplitude de 6,0% da média, muito acima da diferença entre V3 e V4 (no máximo 0,0004%) e do corte das permanências (0,001 s em 98,9 s). Não separamos o quanto ainda resta do viés do início vazio nesse horizonte, e o aquecimento foi avaliado em três cenários, com uma janela curta. Também não testamos `rand()`; com a SciPy, um teste de Kolmogorov-Smirnov sobre amostras de `aleatorio()` faria isso com um programa pequeno, sem mexer no simulador.

Referências

GONZAGA, Flávio Barbieri. **Análise de desempenho: aulas 1 a 7**. Alfenas: Universidade Federal de Alfenas, 2026. Material didático em slides.

HARRISON, J. Michael. **Brownian motion and stochastic flow systems**. New York: John Wiley & Sons, 1985.

KENDALL, David G. Stochastic processes occurring in the theory of queues and their analysis by the method of the imbedded Markov chain. **The Annals of Mathematical Statistics**, v. 24, n. 3, p. 338–354, 1953. DOI: https://doi.org/10.1214/aoms/1177728975.

LITTLE, John D. C. A proof for the queuing formula: $L = \lambda W$. **Operations Research**, v. 9, n. 3, p. 383–387, 1961. DOI: https://doi.org/10.1287/opre.9.3.383.

MORSE, Philip M. Stochastic properties of waiting lines. **Operations Research**, v. 3, n. 3, p. 255–261, 1955. DOI: https://doi.org/10.1287/opre.3.3.255.

ROSS, Sheldon M. **Simulation**. 4. ed. San Diego: Academic Press, 2006.

TRIVEDI, Kishor S. **Probability and statistics with reliability, queuing, and computer science applications**. 2. ed. New York: John Wiley & Sons, 2001.

WHITT, Ward. **Stochastic-process limits**: an introduction to stochastic-process limits and their application to queues. New York: Springer, 2002. DOI: https://doi.org/10.1007/b97479.