MODELAGEM E SIMULAÇÃO DE UMA FILA M/M/1: ANÁLISE DE DESEMPENHO EM DIFERENTES CENÁRIOS

Jeann Victor Batista

Universidade Federal de Alfenas – UNIFAL-MG

Bacharelado em Ciência da Computação

Disciplina: Análise de Desempenho

Professor: Flávio Barbieri Gonzaga

Resumo: Este trabalho analisa um simulador a eventos discretos de uma fila M/M/1 implementado em linguagem C, relacionando seu funcionamento à notação de Kendall, à estabilidade e à Lei de Little. Foram avaliados sete cenários, com intensidades de tráfego entre 0,25 e 1,10, quatro horizontes e 30 repetições por configuração, totalizando 840 execuções da versão original adaptada para testes em lote e 840 de uma versão com correções básicas. Como contribuição metodológica, o estudo combina comparação teórica, intervalos de confiança, conservação de fluxo e análise pareada para distinguir variabilidade amostral de efeitos da implementação. Nos cenários estáveis, as médias aproximaram-se dos valores teóricos com o aumento do horizonte. Para $T = 10^5$, os erros relativos ficaram abaixo de 0,4% nos três primeiros cenários e chegaram a aproximadamente 2,35% nas cargas próximas da saturação. Nos cenários crítico e sobrecarregado, observaram-se crescimento da população final e vazão próxima da capacidade do servidor. A versão original ultrapassou o horizonte solicitado, mas o efeito relativo desse problema diminuiu nas execuções longas. O resíduo de Little foi próximo de zero por construção algébrica, o que limita seu uso como validação independente. Os resultados sustentam a coerência do simulador nas condições avaliadas e mostram que a proximidade da saturação exige maior duração e cuidado na interpretação.

Palavras-chave: teoria de filas; simulação a eventos discretos; M/M/1; Lei de Little; análise de desempenho.

1 Introdução

Em sistemas computacionais, diferentes recursos podem receber solicitações em uma velocidade superior àquela com que conseguem processá-las. Quando o atendimento não ocorre imediatamente, as solicitações permanecem no sistema e formam filas. Esse comportamento está presente, por exemplo, em servidores, roteadores, processadores e sistemas de armazenamento. A análise dessas filas permite compreender como a carga de trabalho influencia a utilização dos recursos, a quantidade de solicitações presentes e o tempo necessário para concluir cada atendimento.

A teoria de filas e a simulação a eventos discretos constituem formas complementares de estudar esses sistemas. A teoria fornece expressões matemáticas para medidas de

desempenho sob determinadas hipóteses, enquanto a simulação reproduz computacionalmente a evolução do sistema e permite observar seu comportamento em condições variadas. Entre os modelos clássicos está a fila M/M/1, caracterizada por intervalos entre chegadas exponenciais, tempos de atendimento exponenciais e um único servidor (TRIVEDI, 2001). A comparação entre teoria e simulação também auxilia na identificação de limitações ou erros de implementação (ROSS, 2006).

Este trabalho parte do arquivo `simulacao_v3.c`, fornecido na disciplina de Análise de Desempenho. O programa gera eventos de chegada e saída, controla a quantidade de solicitações no sistema e calcula ocupação, número médio de solicitações e tempo médio de permanência. A análise examina a influência da carga e da duração das execuções, a variabilidade entre repetições, a conservação do fluxo e o comportamento dos regimes crítico e sobrecarregado. Também investiga o efeito de correções básicas no encerramento da simulação.

O objetivo é analisar o desempenho da fila em diferentes cenários e verificar em que condições os resultados experimentais se aproximam das previsões do modelo M/M/1. Para isso, são empregados a notação de Kendall, a condição de estabilidade, as fórmulas de regime estacionário e a Lei de Little. O estudo compara a versão V3, mantida com sua lógica original, e a versão V4, que corrige problemas de entrada e de encerramento sem introduzir novas medidas de desempenho. Tabelas, intervalos de confiança e gráficos são utilizados para organizar e discutir os resultados.

O artigo está organizado da seguinte forma: a seção 2 apresenta a fundamentação teórica; a seção 3 descreve o código e suas limitações; a seção 4 detalha o experimento e o tratamento estatístico; a seção 5 discute os resultados; e a seção 6 apresenta as considerações finais.

2 Fundamentação teórica

2.1 Processos de chegada e distribuição exponencial

No modelo M/M/1, considera-se que as chegadas formam um processo de Poisson de taxa $\lambda > 0$. Assim, a quantidade $C(t)$ de chegadas observadas em um intervalo de duração t possui distribuição de Poisson:

$$P\{C(t) = k\} = e^{-\lambda t}\frac{(\lambda t)^k}{k!}, \qquad k = 0, 1, 2, \ldots \tag{1}$$

O parâmetro λ representa a quantidade média de chegadas por unidade de tempo. Por exemplo, $\lambda = 0{,}5$ solicitação por segundo corresponde, no longo prazo, a uma chegada a cada dois segundos.

Os intervalos X entre chegadas consecutivas são independentes e seguem uma

distribuição exponencial de taxa λ, cuja função de distribuição acumulada é

$$F_X(x) = P\{X \leq x\} = 1 - e^{-\lambda x}, \qquad x \geq 0. \tag{2}$$

O intervalo médio entre chegadas é $\mathrm{E}[X] = 1/\lambda$. De maneira semelhante, o tempo de atendimento S é exponencial de taxa μ e possui média $\mathrm{E}[S] = 1/\mu$. A distribuição exponencial apresenta ausência de memória, propriedade que permite representar o sistema como um processo markoviano (TRIVEDI, 2001; GONZAGA, 2026).

2.2 Geração de variáveis pela transformada inversa

O simulador gera intervalos exponenciais pelo método da transformada inversa. A partir de uma variável pseudoaleatória uniforme U no intervalo $(0, 1]$, uma amostra exponencial de taxa r é obtida por

$$X = -\frac{\ln(U)}{r}. \tag{3}$$

No código, usa-se $r = \lambda$ para o tempo até a próxima chegada e $r = \mu$ para a duração do atendimento. A função `aleatorio()` produz U, e as expressões que contêm `log(aleatorio())` implementam a Equação 3.

O programa recebe tempos médios, mas os converte internamente em taxas. Se o tempo médio entre chegadas informado for m_c, calcula-se $\lambda = 1/m_c$; se o tempo médio de atendimento for m_s, calcula-se $\mu = 1/m_s$. Por isso, apesar dos nomes das variáveis no código, depois da conversão elas passam a armazenar taxas.

2.3 Notação de Kendall e modelo M/M/1

A notação de Kendall classifica um sistema de filas pela forma $A/S/c$, em que A representa a distribuição dos intervalos entre chegadas, S representa a distribuição dos tempos de serviço e c indica a quantidade de servidores (KENDALL, 1953).

No modelo M/M/1, o primeiro M indica intervalos entre chegadas exponenciais, o segundo M indica tempos de atendimento exponenciais e o número 1 indica um único servidor. Sob as hipóteses usuais adotadas neste estudo, a descrição completa é M/M/1/∞/∞/FCFS: capacidade ilimitada, população potencialmente infinita e atendimento na ordem de chegada (*first come, first served*). Também se pressupõe independência entre os intervalos de chegada e os tempos de atendimento.

No código estudado, os dois símbolos M correspondem às chamadas da transformação inversa usadas para programar chegadas e saídas. O número 1 é representado pela existência de apenas um instante de saída agendado. Como o programa trabalha com medidas agregadas e processa um atendimento por vez, a ordem FCFS é implícita, embora

não sejam mantidos registros individuais das solicitações.

2.4 Utilização e condição de estabilidade

A intensidade de tráfego, também chamada de utilização, é definida por

$$\rho = \frac{\lambda}{\mu}. \tag{4}$$

Em uma fila M/M/1 estável, ρ corresponde à fração de tempo em que o servidor permanece ocupado. A existência de um regime estacionário com médias finitas exige

$$\lambda < \mu \quad \Longleftrightarrow \quad \rho < 1. \tag{5}$$

Quando ρ se aproxima de 1, resta pouca capacidade livre e aumentam a população no sistema, o tempo de permanência e a variabilidade. Para $\rho \geq 1$, não existe distribuição estacionária de probabilidade. No caso crítico, $\rho = 1$, o processo é recorrente nulo: pode retornar ao estado vazio, mas não possui um equilíbrio estacionário normalizável. Quando $\rho > 1$, o processo é transiente e a demanda excedente produz crescimento persistente da população. Uma execução limitada ainda fornece valores numéricos, que dependem do horizonte e não devem ser interpretados como médias de equilíbrio (TRIVEDI, 2001).

2.5 Medidas de desempenho do M/M/1

Seja $N(t)$ a quantidade de solicitações no sistema no instante t, incluindo a que está em atendimento. Sua média estacionária é $L = \mathrm{E}[N]$. A quantidade média apenas na fila é L_q. De modo análogo, W representa o tempo médio total no sistema e W_q representa apenas o tempo médio de espera antes do atendimento.

Para uma fila M/M/1 estável, essas medidas são dadas por

$$L = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda}, \qquad L_q = \frac{\rho^2}{1-\rho}. \tag{6}$$

$$W = \frac{1}{\mu - \lambda}, \qquad W_q = \frac{\rho}{\mu - \lambda}. \tag{7}$$

As saídas das versões V3 e V4 são estimativas de ocupação, L e W. A estimativa de L é temporal, enquanto a de W é indireta e inclui permanências truncadas, conforme discutido na seção 3.5. As grandezas L_q e W_q completam a caracterização teórica, mas não foram incluídas na comparação experimental. Embora L_q possa ser derivado de L e da ocupação quando ambos são medidos corretamente na mesma janela, a subtração $W - 1/\mu$ não resolve as limitações do estimador de permanência em um horizonte finito.

2.6 Lei de Little

A Lei de Little relaciona a quantidade média de elementos, a taxa efetiva de fluxo e o tempo médio de permanência em um sistema estável (LITTLE, 1961). Para o sistema completo,

$$L = \mathrm{E}[N] = \lambda_{\mathrm{ef}} \mathrm{E}[W], \tag{8}$$

em que λ_{ef} é a taxa efetiva de solicitações que atravessam o sistema. Sem perdas ou bloqueios e em regime estável, essa taxa coincide com a taxa externa de chegada λ. Para a fila de espera,

$$L_q = \mathrm{E}[N_q] = \lambda_{\mathrm{ef}} \mathrm{E}[W_q]. \tag{9}$$

Intuitivamente, a quantidade média presente equivale à quantidade que entra por unidade de tempo multiplicada pelo tempo médio de permanência. A lei é mais geral que o modelo M/M/1 e não depende de distribuições exponenciais. Entretanto, no programa original, $\mathrm{E}[N]$ e $\mathrm{E}[W]$ são derivados das mesmas áreas acumuladas. Assim, o resíduo de Little quase nulo verifica a consistência algébrica interna, mas não constitui, isoladamente, uma validação independente. Neste trabalho, essa verificação é complementada pela comparação teórica e pela análise da taxa de chegada e da vazão.

3 Análise do simulador em linguagem C

3.1 Visão geral do simulador

O arquivo `simulacao_v3.c` implementa uma simulação a eventos discretos de uma fila com um servidor. O relógio não avança em passos fixos: ele é deslocado diretamente para a próxima chegada ou saída. Essa estratégia evita processar períodos nos quais o estado não muda e é adequada à representação de filas (ROSS, 2006).

O programa recebe o tempo médio entre chegadas, o tempo médio de atendimento e a duração desejada. Os dois primeiros valores são convertidos em taxas e usados para gerar amostras exponenciais. Durante a execução, são mantidos o relógio, a quantidade de solicitações e os instantes da próxima chegada e da próxima saída. Ao final, o programa apresenta ocupação, $\mathrm{E}[N]$, $\mathrm{E}[W]$ e o resíduo da Lei de Little.

As estruturas do tipo `Info` acumulam áreas no tempo. Uma representa $N(t)$; as outras duas representam os processos acumulados de chegada e de saída. Dessa forma, o programa obtém médias temporais sem registrar o estado em todos os instantes.

3.2 Estado do sistema e escolha do próximo evento

O relógio é armazenado em `tempo_decorrido`. A próxima chegada é registrada em `chegada_cliente`; a próxima saída, em `saida_cliente`. A variável `fila` representa

a população total no sistema, e não apenas quem aguarda: zero significa servidor ocioso, um significa uma solicitação em atendimento e valores maiores que um indicam espera.

Tabela 1: Correspondência entre as grandezas do modelo e as variáveis da V3.

Grandeza	Variável ou acumulador
Relógio t	`tempo_decorrido`
População $N(t)$	`fila` e `en.numero_eventos`
Próxima chegada	`chegada_cliente`
Próxima saída	`saida_cliente`, consultada quando há atendimento
Taxa λ	`intervalo_chegadas`, após a conversão da entrada
Taxa μ	`media_atendimento`, após a conversão da entrada
Chegadas $A(t)$	`ew_chegadas.numero_eventos`
Saídas $D(t)$	`ew_saidas.numero_eventos`
Área sob $N(t)$	`en.soma_areas`

Fonte: elaboração própria, a partir do código fornecido.

Quando o sistema está vazio, a próxima alteração só pode ser uma chegada. Quando está ocupado, o próximo evento é o menor instante entre chegada e saída. Se t_{i-1} é o instante anterior e t_i é o instante atual, o estado anterior permanece válido durante $\Delta t_i = t_i - t_{i-1}$. Esse intervalo é utilizado para atualizar as áreas.

3.3 Tratamento das chegadas e saídas

Em uma chegada, o programa incrementa a população e o contador de chegadas, além de agendar a próxima chegada. Se o servidor estava ocioso, o atendimento começa imediatamente e uma saída é agendada. Caso contrário, a nova solicitação permanece no sistema sem alterar a saída já prevista.

Em uma saída, a população é reduzida e o contador de saídas é incrementado. Se ainda houver solicitações, um novo atendimento começa e outra saída é programada; caso contrário, o servidor torna-se ocioso. O código não armazena uma estrutura de fila com identificadores individuais, mas sua lógica equivale a um servidor FCFS para as medidas agregadas analisadas.

A sequência do laço pode ser resumida pelo seguinte procedimento:

1. Selecionar a próxima chegada ou saída, conforme o estado do servidor.
2. Determinar o intervalo durante o qual o estado anterior permaneceu válido.
3. Acumular as áreas até o instante selecionado, antes de modificar os contadores.
4. Processar o evento e agendar os acontecimentos seguintes.

5. Repetir o procedimento até o encerramento e calcular as estatísticas.

Na V3, o evento selecionado é processado mesmo que ultrapasse o horizonte. Na V4, a verificação do limite ocorre antes do processamento: se o evento está depois de T, as áreas são completadas somente até T e o laço termina.

3.4 Cálculo da ocupação e de $\mathrm{E}[N]$

Na V3, `soma_atendimentos` acumula períodos de serviço e o total é dividido pelo tempo final. Em execuções estáveis e longas, a estimativa deve se aproximar de ρ. O cuidado necessário está na fronteira: um atendimento iniciado antes do horizonte pode terminar depois dele, e a parcela posterior não deveria pertencer à janela observada.

O número médio de solicitações é calculado pela área sob $N(t)$. Denotando por T_{obs} o instante de encerramento efetivo, e considerando os intervalos até esse instante, obtém-se

$$A_N = \sum_i N_{i-1}(t_i - t_{i-1}), \tag{10}$$

e a média temporal é

$$\widehat{\mathrm{E}[N]} = \frac{A_N}{T_{\text{obs}}}. \tag{11}$$

No código, o campo `en.numero_eventos` representa a população atual. Seu nome pode sugerir uma contagem histórica, mas ele é incrementado nas chegadas e decrementado nas saídas.

3.5 Cálculo de $\mathrm{E}[W]$ e resíduo de Little

O código não registra os instantes individuais de chegada e saída. Em vez disso, mantém $A(t)$ e $D(t)$, os totais acumulados de chegadas e saídas. Como o sistema começa vazio e não há perdas,

$$N(t) = A(t) - D(t). \tag{12}$$

Consequentemente,

$$\int_0^{T_{\text{obs}}} N(t)\,dt = \int_0^{T_{\text{obs}}} A(t)\,dt - \int_0^{T_{\text{obs}}} D(t)\,dt. \tag{13}$$

A diferença entre as áreas é dividida pelo número de chegadas para produzir $\widehat{\mathrm{E}[W]}$. Se a_j é o instante de chegada e d_j é o instante de saída da solicitação j, a área acumulada até o encerramento T_{obs} corresponde a

$$\widehat{\mathrm{E}[W]} = \frac{\displaystyle\sum_{j:a_j \le T_{\text{obs}}} \Big[\min(d_j, T_{\text{obs}}) - a_j\Big]}{A(T_{\text{obs}})}. \tag{14}$$

Para solicitações ainda presentes no encerramento, considera-se $d_j > T_{\text{obs}}$. Portanto, cada chegada contribui apenas com o tempo observado até esse instante. A expressão não é uma média de tempos completos dos clientes que saíram: existe truncamento na fronteira, tanto na V3 quanto na V4. Em um sistema estável e com uma janela suficientemente longa, o peso relativo dessa fronteira tende a diminuir; nos cenários sem regime estacionário, o valor permanece uma estatística da janela finita.

Como $\widehat{\mathrm{E}[N]}$, a taxa observada e $\widehat{\mathrm{E}[W]}$ compartilham esses acumuladores, o resíduo calculado por $\widehat{\mathrm{E}[N]} - \widehat{\lambda}\widehat{\mathrm{E}[W]}$ tende a zero por construção, exceto por arredondamento numérico. Na V3, T_{obs} é o tempo final efetivo; na V4, coincide com o horizonte solicitado.

3.6 Versões utilizadas no experimento

O arquivo original `simulacao_v3.c` foi preservado. Para automatizar as execuções, utilizou-se `simulacao_v3_testes.c`. Essa cópia recebe a semente de forma controlada, verifica a leitura de entradas positivas, inicializa a variável de saída e fornece as estatísticas em um formato legível pelo Python. Também remove as mensagens de cada evento, incluindo a impressão cujo especificador de formato não correspondia ao tipo da população. Essas adaptações de interface mantêm, para as entradas válidas avaliadas, a lógica dos eventos e os estimadores da V3, inclusive o processamento além do horizonte e a soma antecipada dos tempos de serviço. A designação V3 nos resultados refere-se a essa cópia de testes.

O arquivo `simulacao_v4.c` não representa um novo modelo nem uma versão instrumentada com novas métricas. Ele mantém a fila M/M/1 e as mesmas medidas da V3, realizando apenas correções básicas: validação das entradas, controle da semente, encerramento exatamente no horizonte solicitado, fechamento das áreas até esse instante, contabilização da ocupação apenas dentro da janela observada e tratamento do caso sem chegadas. Assim, a comparação V3–V4 isola principalmente o efeito dessas correções de fronteira.

O programa `experimentos_mm1.py` não simula a fila. Sua função é compilar e executar os programas em C, organizar as saídas em arquivos CSV, calcular médias, intervalos de confiança e erros relativos e gerar os gráficos. A dinâmica do sistema permanece integralmente nos simuladores em C.

3.7 Limitações consideradas

As execuções começam vazias e não empregam período de aquecimento. O tempo de permanência é calculado indiretamente e sofre truncamento na fronteira, enquanto tempos individuais e percentis não são coletados. Essas escolhas limitam a interpretação das medidas e impedem que o resíduo interno de Little seja tratado como uma validação independente. Além disso, os cenários com $\rho \geq 1$ devem ser analisados como observações

de duração finita.

O uso de `rand()` também requer cuidado. A função produz inteiros em um conjunto finito; ao convertê-los para $(0, 1]$, obtém-se uma grade de valores, e não uma variável uniforme contínua. A qualidade estatística e a sequência gerada dependem da implementação da biblioteca C, e a interface não assegura, por si só, independência entre sorteios. Como o estudo não avaliou correlações nem a aderência das amostras à distribuição exponencial, não é possível quantificar a influência do gerador nos erros observados. Essa é uma limitação do experimento, e não uma evidência de que o gerador tenha causado os desvios.

O original também não verifica o sucesso das leituras nem a positividade das entradas, usa a semente baseada no relógio e imprime a população com `%d`, embora ela seja do tipo `unsigned long`. O formato correto dessa impressão é `%lu`. A variável de saída sem inicialização não é lida antes de receber um valor na sequência normal dos eventos, pois sua consulta é condicionada à existência de atendimento. Da mesma forma, a comparação de instantes com igualdade utiliza um valor selecionado entre os próprios instantes armazenados; não se trata de comparar resultados de cálculos independentes. Em um empate, a V3 dá prioridade à chegada. Esses detalhes devem ser distinguidos dos problemas de horizonte e ocupação efetivamente observados.

4 Metodologia

4.1 Planejamento experimental

Foram comparadas as versões V3 e V4. Em ambas, a taxa de atendimento foi fixada em $\mu = 1$ solicitação por segundo e a taxa de chegada variou conforme a Tabela 2. Os cenários C1 a C5 são estáveis; C6 é crítico; e C7 é sobrecarregado. Na entrada dos programas, as taxas foram convertidas nos tempos médios correspondentes.

Tabela 2: Cenários avaliados no experimento.

Cenário	λ	μ	ρ	Classificação
C1	0,25	1,00	0,25	carga baixa
C2	0,50	1,00	0,50	carga moderada
C3	0,75	1,00	0,75	carga alta
C4	0,90	1,00	0,90	próxima da saturação
C5	0,95	1,00	0,95	próxima da saturação
C6	1,00	1,00	1,00	crítica
C7	1,10	1,00	1,10	sobrecarregada

Fonte: elaboração própria.

Cada cenário foi executado com horizontes de 10^2, 10^3, 10^4 e 10^5 segundos. Para cada combinação, foram realizadas 30 repetições com sementes distintas, tratadas como realizações independentes para o cálculo dos intervalos de confiança. Isso resultou em $7 \times 4 \times 30 = 840$ execuções por versão e 1.680 execuções no total. Dentro de cada combinação de cenário, horizonte e repetição, V3 e V4 receberam a mesma semente, empregando números aleatórios comuns para a comparação pareada. Horizontes diferentes receberam sementes diferentes: os pontos do gráfico de convergência representam conjuntos de execuções distintos, e não prefixos de uma mesma trajetória. Todas as execuções começaram com o sistema vazio e não houve descarte de aquecimento.

4.2 Medidas coletadas e valores teóricos

Foram armazenados a ocupação, E[N], E[W], o resíduo da Lei de Little, a taxa observada de chegada, a vazão de saídas, a população final e o tempo final efetivamente processado. Para C1–C5, os valores teóricos de ocupação, E[N] e E[W] foram calculados, respectivamente, por

$$\rho = \frac{\lambda}{\mu}, \qquad \mathrm{E}[N] = \frac{\rho}{1-\rho}, \qquad \mathrm{E}[W] = \frac{1}{\mu - \lambda}. \tag{15}$$

Não foram atribuídos valores estacionários a C6 e C7, pois $\rho \geq 1$. Nesses casos, a razão λ/μ continua sendo a intensidade de tráfego, mas não pode ser interpretada como uma fração de tempo ocupado superior a 1. Para os indicadores de fluxo da V3, o denominador é o tempo final efetivo; para a V4, é o horizonte solicitado. A população final inclui a solicitação em atendimento, quando houver.

A análise usa os arquivos `resultados_ambas.csv`, com 1.680 registros individuais, `resumo_ambas.csv`, com 56 configurações resumidas, e `little_ambas.csv`, armazenados na pasta `resultados_comparacao`. Os executáveis do lote identificam o compilador GCC 15.2.0, com as opções `-O2 -std=c11 -Wall -Wextra -lm`. A organização das execuções e dos gráficos foi realizada em Python, com Matplotlib, e os intervalos de confiança foram calculados com SciPy. Na revisão do ambiente, verificou-se Python 3.14.4. Os códigos, dados individuais e tabelas completas constituem o material complementar do estudo.

O repositório do trabalho, destinado aos códigos, aos dados completos e às instruções de reprodução, pode ser acessado em `https://github.com/JeannVictor/Trabalho_1_Analise_Desempenho`.

4.3 Tratamento estatístico

Para cada conjunto de 30 repetições, foram calculados a média amostral e o intervalo de confiança de 95% com a distribuição t de Student:

$$\bar{x} \pm t_{0,975;R-1}\frac{s}{\sqrt{R}}, \qquad R = 30. \tag{16}$$

Os intervalos descrevem a incerteza da média entre repetições para uma duração fixada; não eliminam um possível viés de inicialização ou de encerramento. Com $R = 30$, utiliza-se $t_{0,975;29} \approx 2{,}04523$. A aplicação pressupõe repetições adequadas à aproximação pela distribuição t, devendo ser interpretada com cautela em configurações de grande variabilidade. Os limites publicados no CSV foram conferidos a partir das execuções individuais e correspondem a esse quantil.

A precisão relativa foi descrita pela semiamplitude do intervalo dividida pela média:

$$h_r = 100\frac{t_{0,975;R-1}s/\sqrt{R}}{|\bar{x}|}. \tag{17}$$

Uma semiamplitude relativa pequena indica uma média estimada com pouca incerteza entre repetições; isso não equivale a um erro pequeno em relação à teoria. A indicação de pertencimento do valor teórico ao IC foi calculada com os números sem arredondamento. Os intervalos são individuais de 95%, sem ajuste para comparações múltiplas. Nos cenários estáveis, a diferença entre a média simulada e o valor teórico foi expressa pelo erro relativo

$$\text{Erro relativo (\%)} = \left|\frac{\text{simulado} - \text{teórico}}{\text{teórico}}\right| 100. \tag{18}$$

Na comparação de versões, cada diferença é calculada antes de formar a média:

$$d_r = x_{\mathrm{V3},r} - x_{\mathrm{V4},r}, \qquad \bar{d} \pm t_{0,975;R-1}\frac{s_d}{\sqrt{R}}. \tag{19}$$

O gráfico de comparação já utiliza esse IC pareado por cenário e horizonte. A média de $|d_r|$ é usada separadamente para expressar o tamanho das diferenças, sem interpretar essa quantidade como um intervalo de confiança.

Os gráficos foram escolhidos para responder a perguntas distintas e evitar repetição. A comparação teoria–simulação resume a precisão no maior horizonte; a convergência mostra o efeito da duração; os boxplots exibem a variabilidade entre repetições; o gráfico de fluxo verifica a conservação de chegadas e saídas; o excesso de horizonte evidencia o problema da V3; a população final distingue os regimes; e a comparação pareada mostra o efeito das correções da V4. O gráfico isolado de erros relativos não foi incluído porque essa informação já aparece numericamente na tabela de resultados e visualmente na comparação com a teoria.

5 Resultados e discussão

5.1 Comparação entre teoria e simulação

A Figura 1 compara os valores teóricos com as médias da V3 no horizonte $T = 10^5$. Foram incluídos apenas C1–C5, porque somente esses cenários possuem regime estacionário. As barras representam intervalos de confiança de 95% entre as 30 repetições.

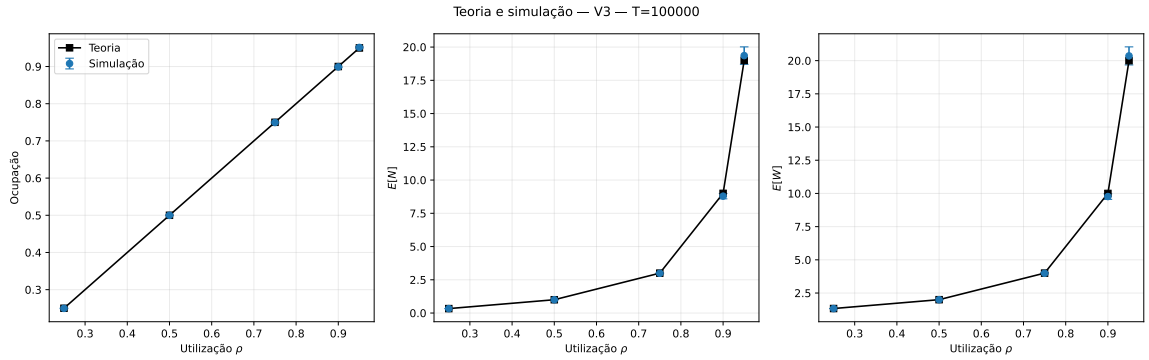


Figura 1: Valores teóricos e simulados pela V3 para $T = 10^5$.

Fonte: elaboração própria.

A Tabela 3 apresenta os valores numéricos correspondentes. Em C1–C3, todos os erros relativos ficaram abaixo de 0,4%. Em C4 e C5, as estimativas continuaram próximas da teoria, mas os erros de E$[N]$ e E$[W]$ aumentaram, atingindo cerca de 2,35%. Esse comportamento é coerente com o crescimento da variabilidade e do tempo de convergência quando ρ se aproxima de 1.

Tabela 3: Resultados da V3 nos cenários estáveis para $T = 10^5$.

Cenário	Medida	Teórico	Média simulada	IC de 95%	Erro relativo (%)
C1	Ocupação	0,2500	0,2497	[0,2490; 0,2504]	0,117
C1	E[N]	0,3333	0,3325	[0,3310; 0,3341]	0,243
C1	E[W]	1,3333	1,3301	[1,3255; 1,3348]	0,240
C2	Ocupação	0,5000	0,4999	[0,4987; 0,5012]	0,013
C2	E[N]	1,0000	0,9981	[0,9919; 1,0044]	0,187
C2	E[W]	2,0000	1,9967	[1,9861; 2,0074]	0,163
C3	Ocupação	0,7500	0,7495	[0,7480; 0,7510]	0,065
C3	E[N]	3,0000	2,9885	[2,9545; 3,0225]	0,382
C3	E[W]	4,0000	3,9865	[3,9427; 4,0302]	0,338
C4	Ocupação	0,9000	0,8990	[0,8972; 0,9007]	0,116
C4	E[N]	9,0000	8,7895	[8,5884; 8,9907]	2,338
C4	E[W]	10,0000	9,7651	[9,5516; 9,9786]	2,349
C5	Ocupação	0,9500	0,9513	[0,9499; 0,9528]	0,142
C5	E[N]	19,0000	19,3593	[18,7033; 20,0154]	1,891
C5	E[W]	20,0000	20,3568	[19,6770; 21,0366]	1,784

Fonte: elaboração própria.

Os intervalos contêm os valores teóricos em C1, C2, C3 e C5 para as três medidas. Em C4, os limites superiores de E[N] e E[W] ficaram ligeiramente abaixo da teoria. Os dados disponíveis não permitem atribuir esse desvio a uma única causa. Flutuação amostral, inicialização vazia e truncamento da janela podem contribuir, mas não foi realizado um experimento que separe esses efeitos.

Na avaliação de 15 ICs individuais, mesmo que a cobertura nominal esteja correta, espera-se em média $15 \times 0{,}05 = 0{,}75$ intervalos que não contenham o valor de referência. Essa contagem esperada não exige independência entre as medidas e não determina a probabilidade conjunta das falhas. Como E[N] e E[W] de C4 compartilham acumuladores, as duas ausências de cobertura são relacionadas. O desvio é compatível com flutuação amostral, mas essa interpretação não exclui possíveis vieses e não permite atribuir uma causa definitiva.

Tabela 4: Precisão relativa das médias da V3 para $T = 10^5$.

Cenário	h_r ocupação (%)	h_r de E[N] (%)	h_r de E[W] (%)	Teoria nos três ICs?
C1	0,29	0,46	0,35	Sim
C2	0,25	0,63	0,53	Sim
C3	0,20	1,14	1,10	Sim
C4	0,20	2,29	2,19	Não
C5	0,16	3,39	3,34	Sim

Fonte: elaboração própria; semiamplitudes relativas dos ICs de 95%.

A Tabela 4 distingue precisão de concordância com a teoria. Para C1 e C2, as semiamplitudes das três médias ficaram abaixo de 1%. Em C3, as de E[N] e E[W] foram próximas de 1,1%; em C4, cerca de 2,2%; e em C5, cerca de 3,3%. Embora o valor teórico esteja no IC de C5, sua média é menos precisa que a de C4. Portanto, cobertura do valor teórico e largura do intervalo respondem a perguntas diferentes. As tabelas completas das configurações podem ser consultadas no material complementar.

5.2 Influência do horizonte de simulação

A Figura 2 apresenta a evolução das médias da V3 nos cinco cenários estáveis. Os cenários crítico e sobrecarregado foram excluídos desse gráfico porque não possuem alvo estacionário e ampliariam a escala de E[N] e E[W], dificultando a leitura dos demais.

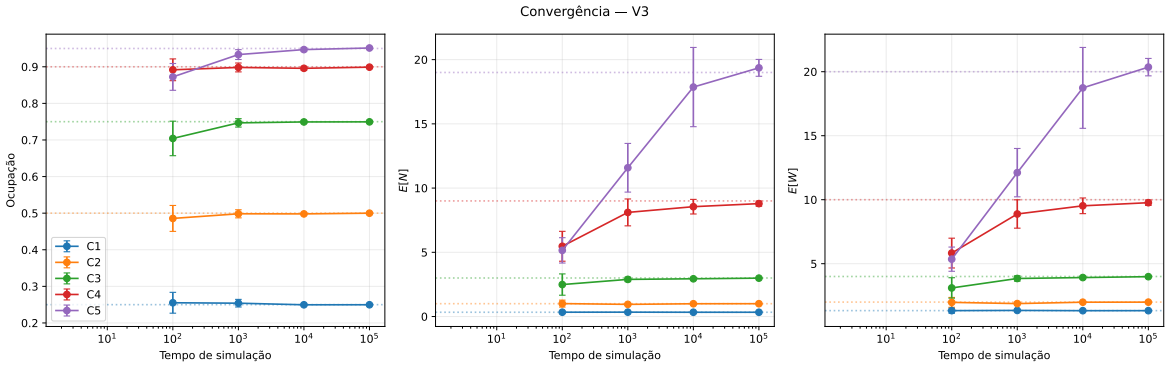


Figura 2: Convergência das medidas da V3 em função do horizonte, com intervalos de confiança de 95%.

Fonte: elaboração própria.

No conjunto dos resultados, horizontes maiores produzem intervalos mais estreitos e melhor aproximação à teoria, especialmente quando comparados com as execuções mais curtas. Essa tendência não exige redução monotônica do erro em cada passagem de horizonte: sementes diferentes geram novas realizações, que podem ficar acima ou abaixo do alvo teórico. Uma execução longa contém mais eventos e reduz o peso proporcional da

inicialização vazia, mas os dados não permitem quantificar separadamente esse viés. Em C4 e C5, os períodos de congestionamento são mais persistentes e as estimativas de E[N] e E[W] continuam mais variáveis. A convergência deve ser avaliada pelas médias e pela largura dos ICs, e não apenas pela forma das linhas que conectam os pontos.

5.3 Variabilidade entre repetições

A Figura 3 mostra as distribuições de E[N] e E[W] nas 30 repetições da V3 para $T = 10^5$. Os dois painéis foram mantidos porque o número de solicitações e o tempo de permanência são medidas diferentes, embora relacionadas pela Lei de Little.

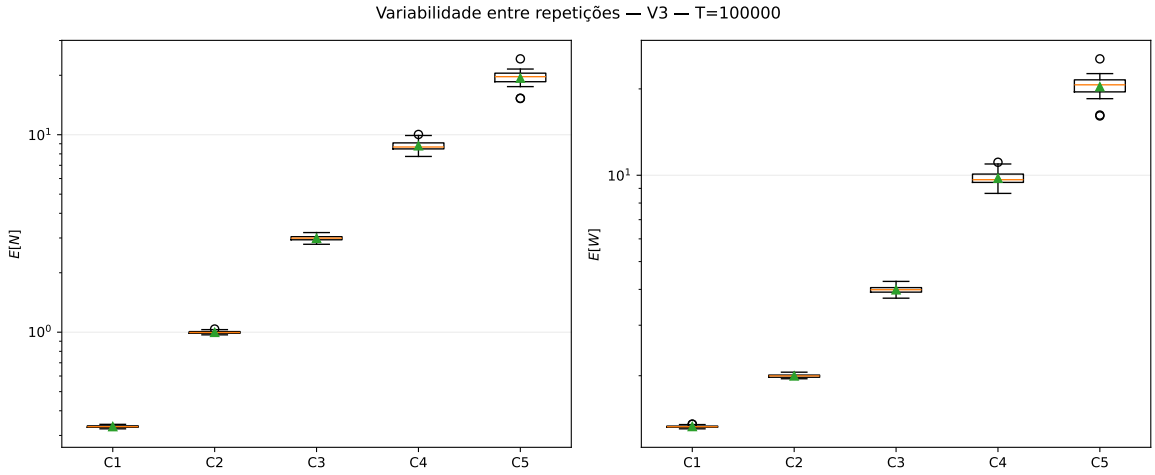


Figura 3: Distribuição de E[N] e E[W] entre as repetições da V3 para $T = 10^5$.

Fonte: elaboração própria.

Os boxplots mostram maior dispersão das estimativas conforme aumenta a carga. Em C1 e C2, os resultados ficam concentrados; em C4 e, principalmente, C5, a amplitude aumenta. Cada ponto utilizado no boxplot é uma média de uma execução, e não um tempo individual de cliente ou uma observação instantânea de $N(t)$. O gráfico descreve, portanto, a variabilidade entre repetições. Esse resultado justifica a apresentação de intervalos de confiança, pois a média isolada ocultaria a incerteza crescente perto de $\rho = 1$.

5.4 Taxa de chegada, vazão e saturação

A Figura 4 compara a taxa de chegada observada com a vazão de saídas no maior horizonte. Essa verificação usa contagens de eventos e fornece uma análise complementar às áreas utilizadas em E[N] e E[W].

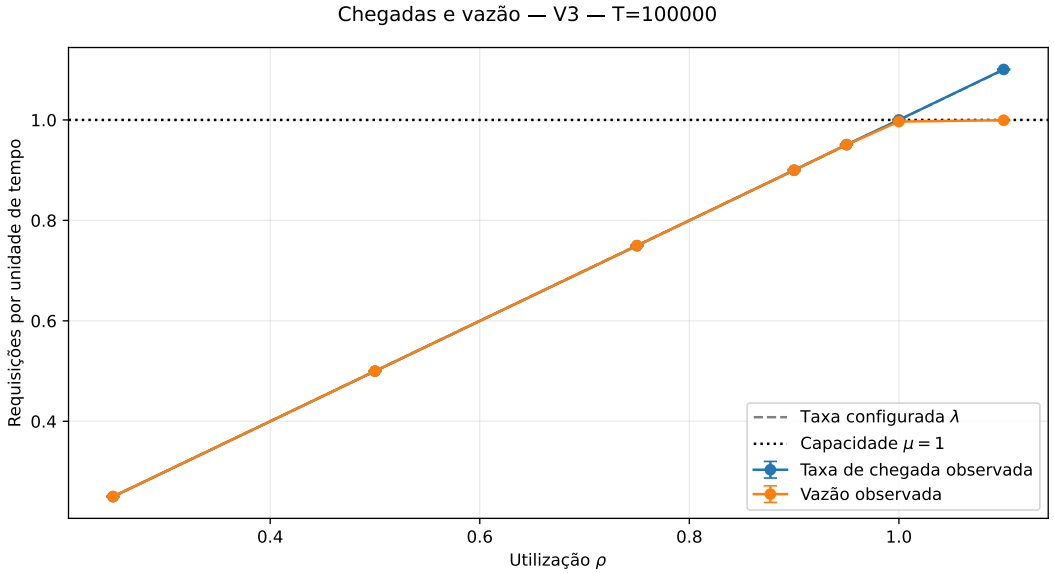


Figura 4: Taxa de chegada observada e vazão da V3 para $T = 10^5$.

Fonte: elaboração própria.

Nos cenários estáveis, taxa de chegada e vazão praticamente coincidem, indicando que o sistema consegue processar a demanda no longo prazo. Em C7, a taxa observada foi aproximadamente 1,1005, enquanto a vazão ficou em 0,9994 solicitação por segundo, próxima da capacidade $\mu = 1$. A diferença de cerca de 0,101 solicitação por segundo acumula-se no sistema. Em C6, pequenas flutuações entre chegadas e saídas também produzem acúmulo, pois não existe folga média de capacidade.

Para cada execução iniciada vazia, a conservação da população estabelece

$$A(T_{\text{obs}}) - D(T_{\text{obs}}) = N(T_{\text{obs}}), \qquad (\widehat{\lambda} - \widehat{v})T_{\text{obs}} = N(T_{\text{obs}}), \tag{20}$$

em que $\widehat{v}$ é a vazão observada. A segunda igualdade foi conferida nos 1.680 registros do CSV: o maior resíduo absoluto ficou abaixo de 10^{-7} solicitação, compatível com o arredondamento das taxas impressas. Trata-se de outra verificação de consistência interna, baseada em fluxo e população, que complementa a análise das áreas sem substituir a comparação com a teoria. Em C7, a diferença de taxas, multiplicada pelo tempo observado, explica a população final próxima de dez mil solicitações.

5.5 Tratamento do horizonte na V3

A Figura 5 mostra a diferença média entre o tempo final processado e o horizonte solicitado na V3. O excesso foi positivo nas configurações avaliadas, confirmando empiricamente o problema de encerramento identificado na leitura do código.

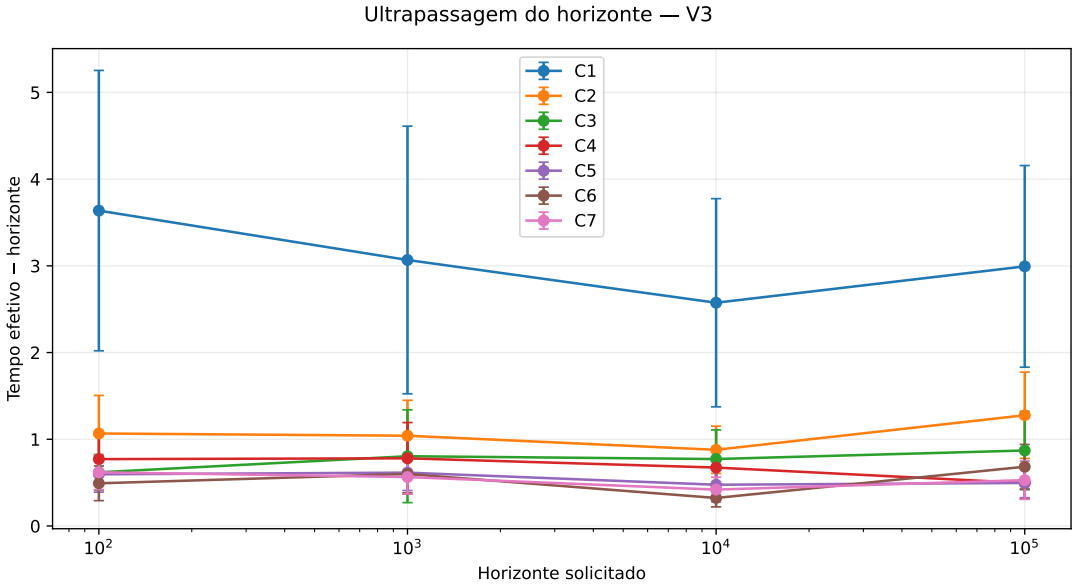


Figura 5: Excesso médio do tempo final sobre o horizonte solicitado na V3.

Fonte: elaboração própria.

O excesso absoluto depende do intervalo até o primeiro evento posterior ao limite e, por isso, não precisa desaparecer quando T aumenta. Seu peso relativo, entretanto, diminui. Por exemplo, em C1 a média do excesso foi aproximadamente 3,64 segundos para $T = 100$ e 2,99 segundos para $T = 10^5$; proporcionalmente, o primeiro caso é muito mais afetado. A V4 interrompe o relógio exatamente em T e fecha as áreas nesse instante, eliminando esse desvio.

5.6 Cenários crítico e sobrecarregado

A Figura 6 apresenta a população final em função de ρ, mantendo o horizonte como séries distintas. O eixo principal é a carga porque o objetivo é evidenciar a transição entre os regimes estável, crítico e sobrecarregado.

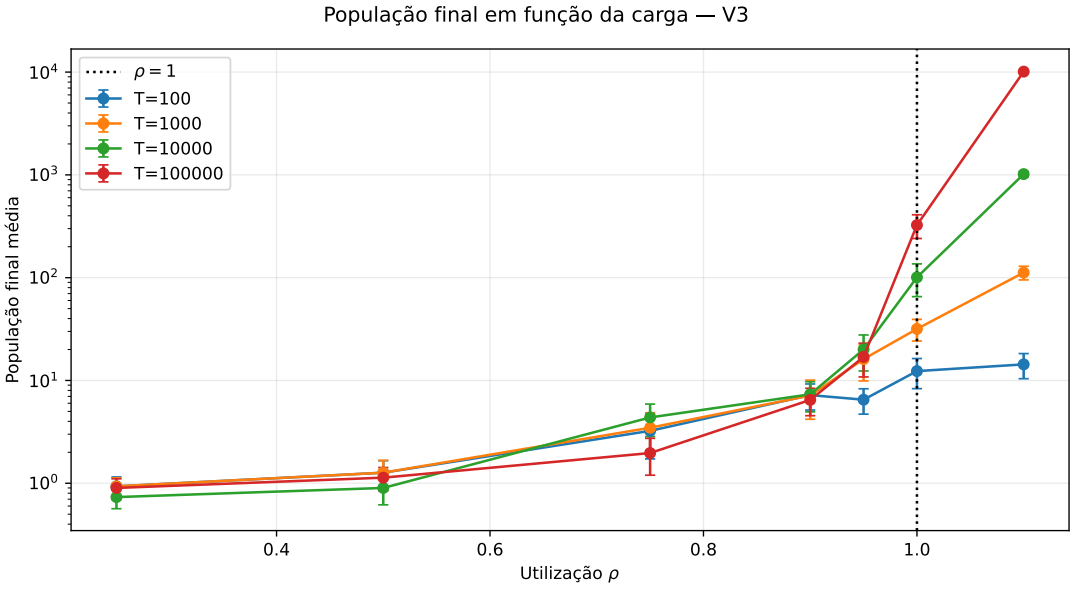


Figura 6: População final da V3 em função de ρ para diferentes horizontes.

Fonte: elaboração própria.

Em C1–C5, a população final permanece relativamente limitada no conjunto de horizontes, embora aumente perto da saturação. Ela é uma observação do encerramento e pode ser elevada mesmo em um cenário estável; não deve ser confundida com $\mathrm{E}[N]$, que é uma média temporal.

Em C6, as médias da população final foram 12,33, 31,73, 100,77 e 324,87 para $T = 10^2$, 10^3, 10^4 e 10^5, respectivamente. Nos três maiores horizontes, a razão $\bar{N}_{\text{final}}/\sqrt{T}$ ficou entre 1,00 e 1,03. Esse padrão é compatível com crescimento na escala de $\sqrt{T}$ e difere do crescimento aproximadamente linear do cenário sobrecarregado. A comparação é descritiva e utiliza quatro horizontes; não constitui um ajuste estatístico nem uma determinação exata da lei de crescimento.

Em C7, a população final média passou de 14,33 em $T = 100$ para 10.107,07 em $T = 10^5$. O último valor é próximo de $(\lambda - \mu)T = 10.000$, coerente com o excesso médio de demanda de 0,1 solicitação por segundo. Esses resultados descrevem janelas finitas e não são estimativas de médias estacionárias.

5.7 Lei de Little

A Tabela 5 resume o valor absoluto do resíduo $\varepsilon_L = \widehat{\mathrm{E}[N]} - \hat{\lambda}\widehat{\mathrm{E}[W]}$ em todas as 840 execuções de cada versão. As médias são da ordem de 10^{-11} e os máximos, de 10^{-9}, refletindo erros numéricos de ponto flutuante e o arredondamento das saídas.

Tabela 5: Resíduo absoluto da Lei de Little nas execuções.

Versão	Média de $\lvert\varepsilon_L\rvert$	Máximo de $\lvert\varepsilon_L\rvert$
V3	$6{,}42 \times 10^{-11}$	$1{,}18 \times 10^{-9}$
V4	$8{,}79 \times 10^{-11}$	$2{,}05 \times 10^{-9}$

Fonte: elaboração própria.

O resultado confirma que os acumuladores internos preservam a identidade utilizada no cálculo. Contudo, como E$[N]$ e E$[W]$ são derivados das mesmas áreas, um resíduo quase nulo não demonstra sozinho que ambas as médias estão corretas. A concordância com as fórmulas teóricas nos cenários estáveis e a compatibilidade entre taxa de chegada, vazão e população final fornecem evidências adicionais e menos circulares.

5.8 Efeito das correções da V4

A Figura 7 apresenta a média das diferenças assinadas V3−V4 e os ICs pareados de 95%, calculados por cenário e horizonte com números aleatórios comuns. Um IC que contém zero indica que a diferença média não foi distinguida de zero pelo procedimento adotado; um IC que não contém zero indica uma diferença detectável, cuja importância prática ainda depende de sua magnitude.

A Tabela 6 resume outra quantidade: a média de $\lvert d_r\rvert$ nos 150 pares de cada horizonte, reunindo os cinco cenários estáveis com 30 repetições cada. Ela expressa o tamanho médio das diferenças sem cancelamento de sinais e não é um IC pareado.

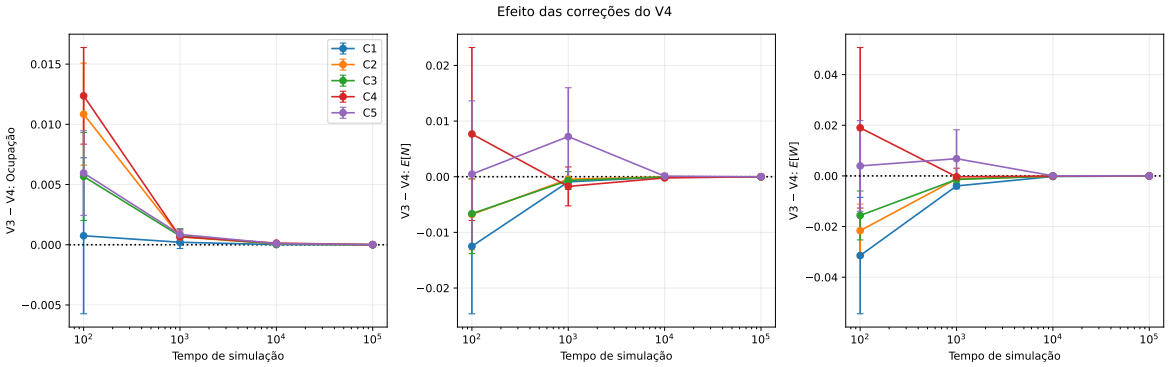


Figura 7: Comparação pareada entre V3 e V4 nos diferentes horizontes.

Fonte: elaboração própria.

Tabela 6: Diferença absoluta média entre V3 e V4 nos cenários C1–C5.

Horizonte	Ocupação	E[N]	E[W]
10^2	0,010652	0,017082	0,040145
10^3	0,001029	0,003604	0,007105
10^4	0,000099	0,000287	0,000611
10^5	0,000009	0,000027	0,000057

Fonte: elaboração própria.

As diferenças são maiores em execuções curtas, nas quais o tratamento do evento posterior ao limite possui maior peso proporcional. Em $T = 10^5$, as diferenças absolutas médias ficam na ordem de 10^{-5} para ocupação e população e de 10^{-5} a 10^{-4} para permanência. Algumas diferenças assinadas continuam estatisticamente detectáveis, mas sua magnitude é pequena diante das próprias medidas. Portanto, uma diferença detectável não implica necessariamente uma alteração importante no desempenho estimado.

As duas versões usam o mesmo gerador e a mesma lógica de sorteios para os eventos compartilhados anteriores ao horizonte. A V3 ainda processa o primeiro evento posterior e pode realizar sorteios adicionais nessa fronteira; a V4 encerra em T. O pareamento reduz a influência de trajetórias diferentes e permite relacionar as discrepâncias às correções de encerramento e ocupação. Os resultados sustentam a coerência da dinâmica central da V3 nas configurações avaliadas e mostram o benefício da V4 para definir uma janela de observação consistente.

6 Considerações finais

Este trabalho analisou o funcionamento de um simulador M/M/1, relacionou sua implementação aos fundamentos de teoria de filas e avaliou seu comportamento em diferentes cargas e horizontes. O experimento combinou sete cenários, quatro durações e 30 repetições, permitindo discutir não apenas médias, mas também incerteza, convergência, conservação de fluxo, saturação e limitações do código.

Nos cenários estáveis, os horizontes maiores ofereceram, no conjunto, melhor aproximação à teoria e intervalos mais estreitos. Para $T = 10^5$, C1–C3 apresentaram erros inferiores a 0,4%, enquanto C4 e C5 tiveram erros de até aproximadamente 2,35% para população e permanência. A precisão relativa também variou: as semiamplitudes dessas medidas ficaram abaixo de 1% em C1 e C2 e ultrapassaram 3% em C5. A ausência de cobertura da teoria em duas medidas relacionadas de C4 foi interpretada com cautela, sem atribuição conclusiva ao transiente inicial.

A análise de fluxo mostrou que chegadas e saídas se equilibram quando $\rho < 1$, enquanto a vazão se limita à capacidade do servidor no cenário sobrecarregado. A

população final crescente em C6 e C7 demonstrou por que não se devem aplicar fórmulas estacionárias quando $\rho \geq 1$. O resíduo de Little permaneceu numericamente próximo de zero, mas foi interpretado como uma identidade interna dos acumuladores e não como prova independente da correção do simulador.

A comparação pareada confirmou diferenças maiores nos horizontes curtos e pequenas em magnitude nas execuções longas. A V4 encerrou exatamente no horizonte solicitado e ajustou a contabilização da ocupação na janela. Esses resultados mostram que a correção de fronteira melhora a definição da observação, mesmo quando sua influência prática nas médias de longo prazo é pequena.

O início vazio, a ausência de aquecimento, o cálculo truncado de W e a falta de avaliação estatística do gerador limitam as conclusões. O registro incompleto do ambiente também restringe a reprodução numérica entre máquinas. A coleta de tempos individuais poderia ampliar a análise e permitir uma verificação independente da Lei de Little. Nas condições estudadas, o simulador reproduz os principais comportamentos de uma fila M/M/1. Sua validação, porém, exige observar conjuntamente a concordância com a teoria, a precisão das estimativas e a forma como o código mede cada grandeza.

Referências

GONZAGA, Flávio Barbieri. **Análise de desempenho: aulas 1 a 7**. Alfenas: Universidade Federal de Alfenas, 2026. Material didático em slides.

KENDALL, David G. Stochastic processes occurring in the theory of queues and their analysis by the method of the imbedded Markov chain. **The Annals of Mathematical Statistics**, v. 24, n. 3, p. 338–354, 1953. DOI: `https://doi.org/10.1214/aoms/1177728975`.

LITTLE, John D. C. A proof for the queuing formula: $L = \lambda W$. **Operations Research**, v. 9, n. 3, p. 383–387, 1961. DOI: `https://doi.org/10.1287/opre.9.3.383`.

ROSS, Sheldon M. **Simulation**. 4. ed. San Diego: Academic Press, 2006.

TRIVEDI, Kishor S. **Probability and statistics with reliability, queuing, and computer science applications**. 2. ed. New York: John Wiley & Sons, 2001.